


Predicción del Default Crediticio

Dos caras de la moneda para enfrentar un problema de negocio: Una visión técnica y un análisis de la ética en ciencia de datos

Andrés

Aplicar técnicas de Aprendizaje de Máquina para otorgar mejores créditos

Mayo 2023



Prólogo

¿Cuál fue el resultado? Ahorro potencial de 208,708 USD cada año, ~3 millones de pesos, al sustituir el uso de SAS por Anaconda Server. Compartí este ejercicio al área de riesgos de Banco y ayudó en la adopción interna de técnicas de Machine Learning y programación en Python y R. Este proyecto también ayudó en generar ideas adicionales sobre dónde aplicar Machine Learning en otras aristas del negocio

Este documento inicia situando al lector en un México post pandemia, en 2023. Transmite brevemente el quehacer de un banco como entidad financiera y su operación en alto nivel. Enseguida, introduce la necesidad de predecir el default en préstamos personales.

Contenido

Sección	Tema	Página
Inicio y herramientas utilizadas	Introducción al proyecto y su propósito tangible	5
	Toolbox para el proyecto	6
Descripción de la situación y problemas que inspiraron este proyecto	Entorno y Modelo de negocio de la empresa	7-10
	Modelo operativo de la empresa	11
	Lienzo de la propuesta de valor	12
	Propuesta de valor al segmento escogido	12
	Lienzo del modelo de negocio	13
	Diagrama MIDE	13
Solución desarrollada y Producto Mínimo Viable	Atributos de la solución relacionados con la Maestría en Ciencia de Datos	14
	Datos	14-15
	Algoritmos	16-20
	Interfaces	21
Priorización según la matriz de impactos de iniciativa de mejora	¿Por qué este proyecto tuvo más prioridad que otros?	22
	Roadmap de innovación/adopción de ciencia de datos en la empresa.	23
	¿Qué lugar ocupa este proyecto en la estrategia de innovación de la empresa?	23
Estrategia y obstáculos relacionados con la solución propuesta	Cuadro estratégico Blue Ocean	24
	Matriz de las cuatro acciones	25
	Adopción de la solución	26
	Obstáculos que se debieron superar	26
	Obstáculos aún no superados	26
	Tabla de experimentación y resultados obtenidos	26
Monitoreo y Resultados	Indicadores de éxito del proyecto	27-28
	Impacto en los estados financieros	29
	Aspectos éticos en los datos y algoritmos utilizados	30-38

Introducción

Negocio

Propósito Tangible:

Buscar un ahorro de 208,708 USD cada año, ~3 millones de pesos, al sustituir el uso de SAS por Anaconda Server. El IaaS y SaaS de SAS contiene Base SAS, ODBC, ETS, ML, STAT, CONNECT, entre otros. Además de compartir al área de riesgos de Banco este ejercicio de predicción de defaults crediticios para promover la adopción de Técnicas de Machine Learning internamente. La información es pública y de individuos Estadounidenses. Se pretende ilustrar una forma más segura de prestar dinero a clientes bancarios.

Antecedentes y Contexto del Proyecto:

En un México post pandemia - COVID-19- los bancos se beneficiarían de poder predecir con certeza a quiénes prestarles para evitar clientes morosos.

La regulación y el entorno bancario cambiaron radicalmente, generando un entorno competitivo complejo para los integrantes del gremio bancario.

Propuesta del Proyecto Final

Promover el uso de técnicas de Machine Learning para generar un modelo predictivo en la asignación de créditos a personas físicas. La base de datos que se usa - si es - información real, pero de clientes de LendingClub. Son préstamos otorgados en 2007 a 2018 en >2 millones de filas y 150 variables dentro de un archivo CSV de ~1GB. LendingClub es una compañía establecida en San Francisco California y fue la primera peer-to-peer en registrarse en la SEC (Securities & Exchange Commission) de EUA.

Criterios y principios que debe cumplir actualmente el proyecto

Se definen a detalle en la sección de contenido y se dividen principalmente en 1) Descripción 2) Solución 3) Priorización 4) Estrategia y 5) Monitoreo.

Ética

Definición y justificación del problema:

¿Qué tanta información debo obtener del cliente? ¿Cómo debo usarla? Mientras más información tenga del cliente podría predecir mejor un default crediticio. Aquí, se justifica un diseño ético para considerar la parte de negocio y también la parte ética, legal y riesgos relacionados a con la privacidad de los clientes.

Revisión de preocupaciones éticas:


En la búsqueda por perfeccionar el proyecto, se analizarán los 8 temas para inteligencia artificial y ciencia de datos 1) privacidad 2) responsabilidad 3) Seguridad y Protección 4) Transparencia y características explicables 5) Justicia y no discriminación 6) Control Humano 7) Responsabilidad Profesional y 8) Valores Humanos.

Framework de diseño ético


En este documento, se explora el algoritmo en alto nivel mediante la auditoría algorítmica, para esto, se propone herramientas de gestión como OpenPages de IBM, LINDDUN y una matriz de impactos (Heat-Map).

Criterios de análisis de riesgos y beneficios

Incluir un marco de revisión ético a los algoritmos disminuye el riesgo reputacional que la compañía pueda enfrentar y mejora la relación con el cliente mostrando transparencia en sus procesos.



Toolbox



Cimientos del proyecto



Machine Learning

- Análisis Exploratorio: Variables categóricas y numéricas
- Pre procesamiento y transformaciones
- Modelos supervisados
- Evaluación de modelos
- Pipelines
- Grid-searching

Business Acumen

- Business Model Canvas y Value Proposal
- Materiales, Información, Dinero y Estancos (MIDE)
- Innovation Roadmap
- Strategy Map
- Tabla de experimentación

Data Viz

- Dashboards: Seaborn (Python), Gradio y otros
- Storytelling

8 - Principios de Ética

- Privacidad, Responsabilidad, Seguridad y Protección, Transparencia, Justicia, Control Humano, Responsabilidad, Valores Humanos
- Audit Framework
- SHAP

Partes del Roadmap Académico Utilizadas

Semestre 1

Visualización de Datos

- Fundamentos de bases de datos

Estadística

- Fundamentos ciencia de datos

Aprendizaje de máquina I

- Grandes datos

Semestre 2

Liderazgo

Econometría

- ML en grandes datos

- Cloud Computing

- NLP

Aprendizaje de máquina II

Semestre 3

Ética en ciencia de datos

Proyecto de Aplicación

Deep Learning

Protección Datos Personales

Descripción
 p. 7-13

Solución
 p. 14-21

Priorización
 p. 22-23

Estrategia
 p. 24-26

Monitoreo
 p. 27-38

Situarnos en el tiempo y en el entorno local

Comencemos con un panorama para visualizar un México Post-Pandemia COVID-19

En un México como el que se vive en inicios del 2023, es muy importante ser una empresa digitalizada. La pandemia detonó la transformación tecnológica tanto de gobiernos como del sector privado; las familias se vieron en la necesidad de pedir préstamos por desempleo o por gastos médicos. Los bancos, comenzaron un camino apresurado a digitalizarse y hacer uso de herramientas tecnológicas para gestionar el riesgo en la colocación de créditos. Así es como nace la necesidad de este proyecto, tratar de predecir un default crediticio.

Pandemia en gráficos (Periódico El Economista, 2021)



Un solo camino por andar para los Bancos en México, según Forbes

De acuerdo con Forbes, en su artículo -Las 10 tendencias que darán forma a la banca este año- lanzado en 2021 vemos que la pandemia incrementó la importancia de proyectos como el que se presenta en este documento. El uso de nuevas tecnologías brincó a las primeras prioridades del sector bancario.

"A medida que crece el escepticismo de los clientes, los bancos están redescubriendo sus raíces empáticas y creando funciones que ponen a los usuarios a cargo de las decisiones sobre tarifas. Ahora no tienen más remedio que ser más transparentes con respecto a las tarifas y, afortunadamente, las capacidades digitales, de IA y de la nube están convergiendo para proporcionar la plataforma perfecta para el asesoramiento personalizado."

BBVA: ¿En qué ayuda Machine Learning en el sector Bancario?

En 2019 en vísperas de la Pandemia en México. BBVA ya entendía la importancia de Machine Learning para los objetivos empresariales de los bancos. Con lo anterior podemos detectar 3 aristas importantes donde el aprendizaje de máquina resulta ser de gran importancia para los bancos.

- Primero, los **servicios a la medida**, "Hoy en día tenemos una visión unificada de la huella del cliente en todas sus vertientes (estados financieros de múltiples cuentas, productos contratados, transaccionalidad, etc.)"
- También está la **reducción de incertidumbre** mediante la mejora de los servicios financieros, "gracias a una valoración de riesgos basada en una huella digital ampliada del cliente".
- Por último, la **detección de fraude**, "El año pasado (2018), BBVA trabajó con un equipo de investigadores del Massachusetts Institute of Technology (MIT) en el desarrollo de un modelo que puede reducir en un 54% el nivel de falsos positivos en la detección de operaciones fraudulentas con tarjeta, gracias a algoritmos basados en 'machine learning'".

Descripción
p. 7-13

Solución
p. 14-21

Priorización
p. 22-23

Estrategia
p. 24-26


Monitoreo
p. 27-38

Pronóstico simple de préstamos personales de Banco

¿Hacia dónde va la tendencia de los préstamos personales en Banco? Para esto obtenemos un histórico extraído del portafolio de información de la Comisión Nacional Bancaria y de Valores.

Posteriormente, tomamos datos de Banca Múltiple, Banco Consolidado y bajamos datos desde 2016 hasta 2023. Finalmente distinguimos la cartera vigente de la cartera vencida de préstamos personales


Revisando la tendencia de los préstamos personales es posible visualizar alguna necesidad de negocio que requiera el uso de Machine Learning para aliviar un problema. Vemos que durante pandemia hubo un pico de cartera vencida que aunque ha disminuido continuamente, no ha desaparecido del todo.




¿Qué camino abordar para predecir el comportamiento de la cartera de préstamos personales? Escogí ARIMA, An autoregressive integrated moving average, por 2 razones principales, la primera es por que ARIMA se utiliza en diferentes tipos de datos financieros, macroeconómicos y estimaciones futuras de series de tiempo. La segunda, porque es el modelo que más usamos en la maestría y me siento más cómodo con él. Con el modelo ARIMA esperamos estimar la volatilidad del crecimiento o decrecimiento mes a mes de la cartera vencida y vigente. El primer paso es obtener las diferencias mes a mes de los préstamos y verificar que estas series tengan estacionariedad (propiedades de una serie no varían con el tiempo). Después, obtener gráficos con Autocorrelation Function (ACF) y Partial Autocorrelation Function (PACF) para visualizar la aplicabilidad de un modelo ARIMA (Auto-Regressive Integrated Moving Average). En este proyecto se usó R para todos los cálculos para el forecast.

Visualizar componentes de las diferencias mes a mes: Time Series Decomposition

Cartera vencida



Cartera vigente



Podemos ver una tendencia en la cartera vencida, no así de claro en la cartera vigente, tenemos que hacer más estudios para concluir si un ARIMA puede ser útil en este caso. Aquí se asume que el futuro se parece al pasado, nuestro problema principal es que estudiamos en un periodo de crisis por COVID-19

Descripción
p. 7-13**Solución**
p. 14-21**Priorización**
p. 22-23**Estrategia**
p. 24-26**Monitoreo**
p. 27-38

Estacionariedad: Ver si las propiedades de la serie permiten predecir el futuro

Cartera vencida

Augmented Dickey-Fuller Test

```
data: cartera_vencida
Dickey-Fuller = -3.8482, Lag order = 4, p-value = 0.02115
alternative hypothesis: stationary
```

P-value < 0.05 rechazamos hipótesis nula y determinamos que la serie es estacionaria (predecible con ARIMA)

Cartera vigente

Augmented Dickey-Fuller Test

```
data: cartera_vigente
Dickey-Fuller = -2.7302, Lag order = 4, p-value = 0.2773
alternative hypothesis: stationary
```

P-value > 0.05 rechazamos hipótesis alternativa y determinamos que la serie es no-estacionaria (problemas con ARIMA)


¿Cómo sería el pronóstico de la cartera de préstamos personales usando ARIMA?

Usar Autocorrelation Function (ACF) y Partial Autocorrelation Function (PACF) puede ayudar

Cartera vencida


En la gráfica de autocorrelación podemos ver las correlaciones entre los retrasos 0.1 y 0.2 como las más significativas y una forma geométrica en el decaimiento. Todos los demás retrasos caen dentro de las bandas azules del 95% de confianza, es decir, son negligibles.

Series cartera_vencida



En la gráfica PACF vemos que hay retrasos en 0.2 y 0.7 como los más significativos. Tomando en cuenta que la gráfica ACF decae de forma geométrica y aquí tenemos un punto significativo cerca del retraso 1 con PACF nuestro modelo ARIMA puede resultar como (1,0,0). El próximo paso será realizar auto arima para validar lo que estamos proponiendo.


Series cartera_vencida



Cartera vigente


En este caso, a diferencia de la cartera vigente, no es tan claro que los retrasos vayan disminuyendo geométricamente, por el contrario, se pueden visualizar retrasos significativos en 0.1 y 0.9. Podríamos sugerir un modelo Moving Average (1).

Series cartera_vigente



Poco a poco se ven los retrasos disminuyendo conforme se visualiza la gráfica hacia retrasos más grandes y casi todos ellos muy cerca de las bandas del 95% de confianza, podríamos descartarlos. De esta forma nuestro modelo ARIMA podría resultar como un ARIMA(0,0,1). Falta corroborar esta parte haciendo un auto arima.

Series cartera_vigente



Descripción
p. 7-13

Solución
p. 14-21

Priorización
p. 22-23

Estrategia
p. 24-26

Monitoreo
p. 27-38

Ambas carteras con residuales independientes p-value > 0.05 (Box-Ljung Test)

Si los residuos son independientes, las observaciones en un período de tiempo específico son aleatorias e independientes. Si las observaciones no son independientes, la autocorrelación puede reducir la exactitud de un modelo predictivo basado en el tiempo, y conducir a una interpretación errónea de los datos.

Cartera vencida

Box-Ljung test

```
data: residuals(modelo_c_vencida)
X-squared = 0.52155, df = 1, p-value = 0.4702
```

Cartera vigente

Box-Ljung test


```
data: residuals(modelo_c_vigente)
X-squared = 0.17196, df = 1, p-value = 0.6784
```

Residuos tienen un comportamiento normal

La regresión lineal asume que hay una relación lineal entre X y Y. Segundo, que los residuales son independientes como lo probamos con un Box-Ljung test. Debemos observar otra condición, que los residuos están distribuidos normalmente, para esto usamos un Q-Q plot donde la línea representa una distribución normal y los puntos son los residuales. Mientras los residuales se parezcan más a la línea se puede asumir una distribución normal


Cartera vencida

Normal Q-Q Plot




Cartera vigente

Normal Q-Q Plot




Cartera vencida, pronóstico de diferencias

Forecasts from ARIMA(1,0,0) with zero mean



Cartera vigente, pronóstico de diferencias

Forecasts from ARIMA(0,1,1)



Vemos que la cartera vencida irá disminuyendo hacia 2024, pero cada vez menos. **El algoritmo ayudaría a bajar esta cartera aún más.**

El forecast muestra una caída pronunciada, tiene lógica se espera que los clientes paguen préstamos emergentes desde la pandemia



Descripción
p. 7-13**Solución**
p. 14-21**Priorización**
p. 22-23**Estrategia**
p. 24-26**Monitoreo**
p. 27-38

Modelo de negocio de la empresa

Radiografía panorámica de un banco en México

Este documento propone la predicción de default crediticio en clientes con el fin de mejorar el otorgamiento de créditos. Para lo anterior, se hace uso de técnicas de machine learning vistas en la maestría así como la gestión de proyectos.

¿Qué es lo que hace el banco? Acepta depósitos corrientes y de ahorro y hace préstamos bajo la figura de una entidad financiera con licencia para operar en México. La entidad también proporciona servicios como cuentas individuales de jubilación, certificados de depósito, cambio de divisas y cajas de seguridad. El Grupo Financiero puede estar dividido en banca minorista, comercial, corporativa, casa de bolsa y otros.

Antes de comenzar, es necesario precisar en alto nivel las funciones del banco y cómo está constituido tanto en su centro o core banking como en la periferia o las funciones y procesos de soporte.

Diagrama de Core Bancario para México en Alto Nivel - ¿Qué hay dentro de un banco?

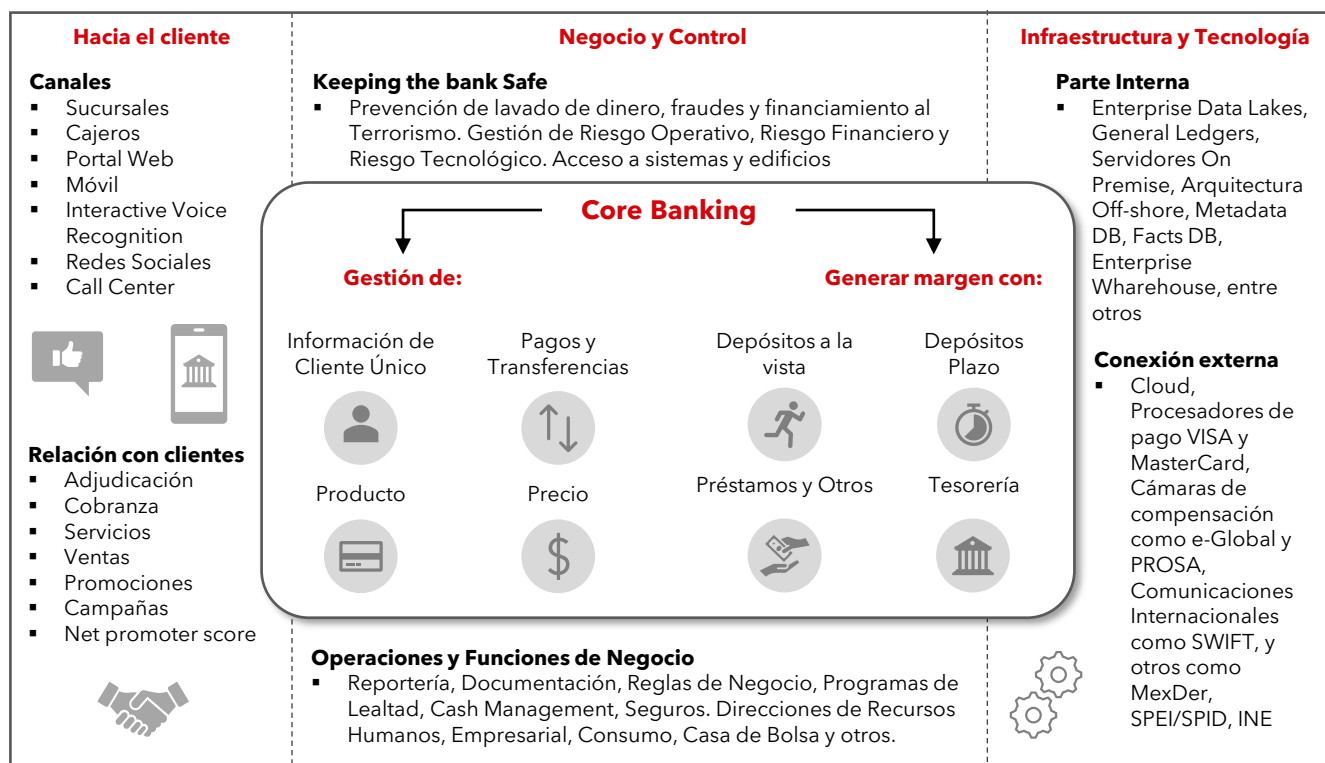



Diagrama generado a través de la experiencia del autor en el sector financiero

Un poco de Historia de la Banca en México: “La historia de la banca en México está ligada a la evolución de la economía local, tanto que ha sido partícipe de sus momentos de expansión como de crisis” (Real Estate & LifeStyle). En años próximos a la Revolución en 1910, la congregación de bancos en México se componía de 24 bancos de emisión (Banco Nacional de México y el Banco de Londres, por ejemplo). Posteriormente, en el México de los 80s, sumido en una crisis económica y una fuerte devaluación, el presidente José López Portillo decretó la expropiación de la banca privada. Diez años más tarde, se creó el Comité de Desincorporación Bancaria que ejecutó la privatización. En esa misma década (90s) se genera el Fondo Bancario de Protección al Ahorro (Fobaproa) para enfrentar problemas extraordinarios. En la época de los 2000, los bancos extranjeros han tomado control de bancos locales, tal es el caso de Citi con Banamex, HSBC con Bital, Serfin con Santander e Inverlat con Banco. Hoy los seis grandes bancos de México: BBVA Bancomer, Banamex, Santander, Banorte, HSBC y Banco compiten en el universo de más de 50 bancos en un entorno de alta competitividad y digitalización postpandemia.

Descripción
p. 7-13**Solución**
p. 14-21**Priorización**
p. 22-23**Estrategia**
p. 24-26**Monitoreo**
p. 27-38

Una era de divergencia para el sector

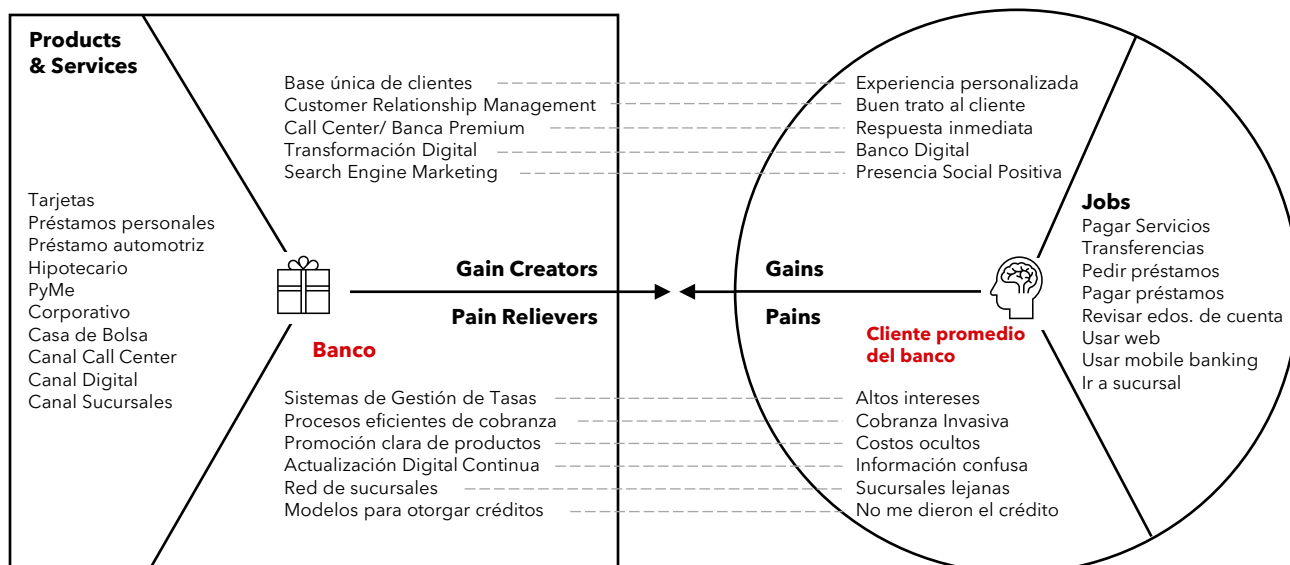
Según Dietz y Kincses en su artículo "A new era of divergence" de McKinsey & Company la brecha entre los bancos con el mejor desempeño y el peor desempeño se hace cada vez más grande y es debida a factores relacionados con la **excelencia operativa** y sus modelos de negocio. Si un banco en México desea seguir siendo competitivo debe mantener el paso con los líderes o estaría destinado a quedar muy alejado del top 10%



Inversiones enfocadas en temas de datos, big data, cloud y otros

De acuerdo con Sharma, Sidhu y Sohail (The Future of AI in Banking, 2021), los bancos pueden beneficiarse al aprovechar los datos de los clientes para identificar señales de advertencia de posibles morosidad e incumplimientos, predecir por qué los clientes podrían perder pagos y ofrecer soluciones personalizadas para ponerse al día. Además, el 86% de los usuarios de la inteligencia artificial en servicios financieros dicen que la inteligencia artificial será muy o críticamente importante para el éxito de su negocio en los próximos dos años. Bajo esta misma línea de ideas **este proyecto de default crediticio cobra importancia dado el entorno actual.**

Lienzos: Propuesta de Valor y Modelo de Negocio

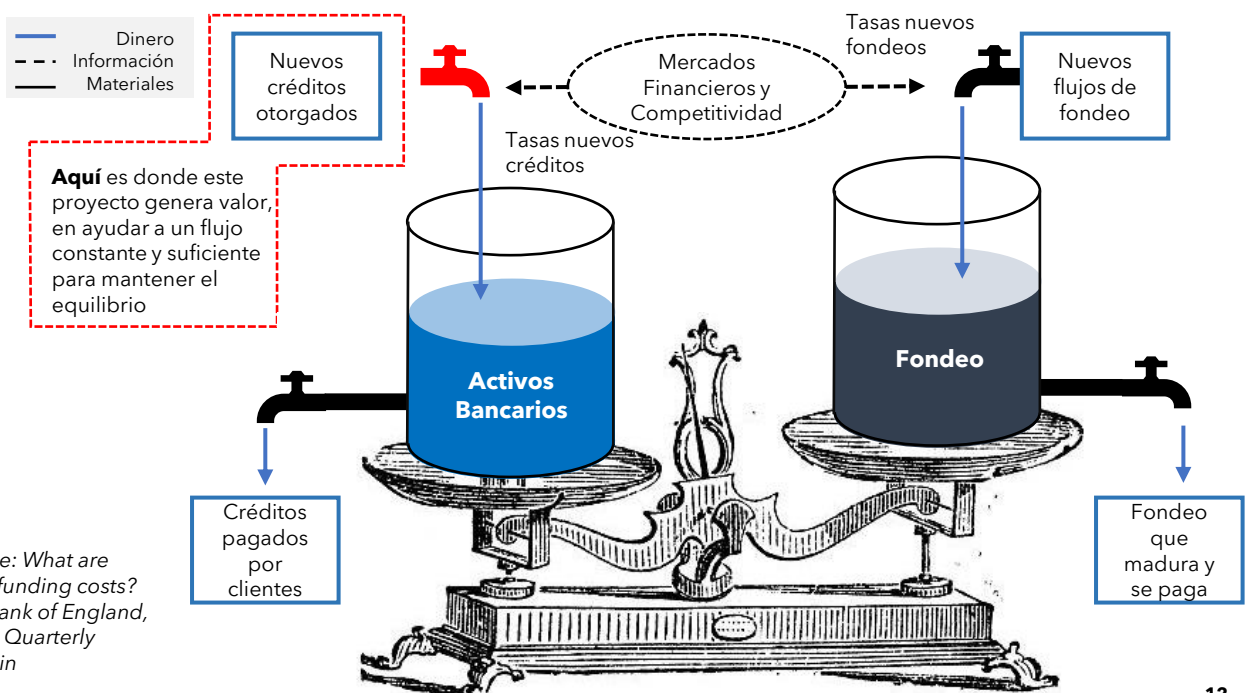


Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
Lienzo del Modelo de Negocio del Banco				
Key Partners Inversionistas Subsidiarias Otros bancos CNBV Banxico Otros reguladores Proveedores INE VISA MasterCard PROSA / eGlobal MexDer Valmer	Key Activities Hipotecas Préstamos Retail Corp. / Mercados Casa de Bolsa Seguros Tarjetas Operaciones Gestión de Riesgos	Value Propositions Desarrollo sostenible Instrumentos Financieros a la medida El cliente primero Banca Premium MultiRed Productos para auto, seguros, tarjetas de crédito, microcréditos, entre otros Ser el top de los bancos en hipotecario Créditos adecuados al cliente	Client Relationships Conveniencia (red de sucursales) ESG Programas de Lealtad Redes sociales Reputación de marca Asistencia 24/7 Inclusión	Customer Segments Persona Física Persona Moral PyMe Corporativos Gobierno Gen Z Millenials Gen X BabyBoomers UHNW HENRY
	Key Resources Multinacional MultiRed en México (~9000 cajeros)		Channels Banca en línea Banca móvil Sucursales Cajeros Call Center Oficinas Corporativas	
Cost Structure Oficinas, Sucursales, Empleados, Impuestos, Legal, Seguridad Corporativa, Red de Cajeros, Costo Financiero (Tesorería), Marketing, Mantenimiento Inmobiliario, Infraestructura IT y otros.			Revenue Streams Intereses, comisiones, retornos sobre inversiones, garantías, ganancias por precios de transferencia, mercados globales y otros.	

Diagrama generado a través de la experiencia del autor en el sector financiero

Diagrama MIDE (Bucket & Scale): Materiales, Información, Dinero y Estanques

Con lo anterior, ya tenemos una idea general del ecosistema que rodea a un banco y la relación que tienen los clientes con la institución. ¿Cómo describimos el comportamiento del banco cuando existe interacción con los clientes? Para esto, usamos MIDE.



Fuente: What are bank funding costs? The Bank of England, 2014, Quarterly Bulletin


Descripción
p. 7-13Solución
p. 14-21Priorización
p. 22-23Estrategia
p. 24-26Monitoreo
p. 27-38

Solución desarrollada y producto mínimo viable

Atributos de la solución relacionados con la Maestría en Ciencia de Datos

Antes de comenzar, un poco de contexto: Los datos reales a menudo no están organizados, son redundantes o les faltan elementos. Primero, debemos limpiar y preparar los datos, este paso es crucial en el flujo de trabajo de aprendizaje automático y también, el que ocupa más tiempo. Tener datos de entrada limpios significa que se puede obtener un modelo más preciso en el futuro. Los datos pueden ser estructurados, semi estructurados o no estructurados. Después de limpiar, se debe convertir datos en formatos válidos que se puedan alimentar a los flujos de aprendizaje de máquina. Finalmente, estos conjuntos de datos se dividen en grupos de datos de entrenamiento y prueba. El conjunto de datos de entrenamiento se utiliza para entrenar el modelo. El conjunto de datos de prueba se utiliza para validar el modelo.

¿Cómo relacionar los atributos de la solución con la Maestría en Ciencia de Datos? Fácil, a través del proceso de aprendizaje de máquina step-by-step, como sigue:




Datos


Son préstamos otorgados entre 2007 y 2018 en >2 millones de filas y 150 variables dentro de un archivo CSV de ~1GB. LendingClub es una compañía establecida en San Francisco California y fue la primera peer-to-peer en registrarse en la SEC (Securities & Exchange Commission) de EUA. La información que se ingresa y los algoritmos se encuentran en mi GitHub: <https://github.com/coyoacan>

De las 150 variables, existen datos que comúnmente se encuentran dentro de los registros de clientes bancarios como la cantidad del préstamo, ingresos reportados por el cliente, su dirección, tipo de empleo y en este caso se utiliza FICO (su equivalente en México sería la calificación de buró de crédito).

Tipo de datos



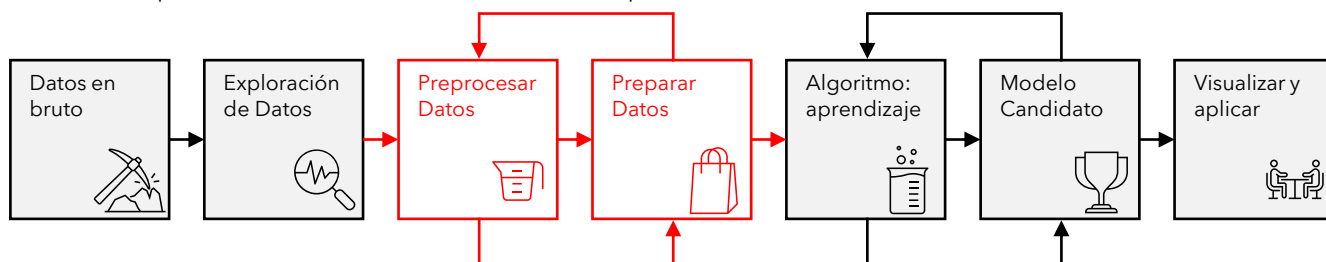
Variables casi vacías



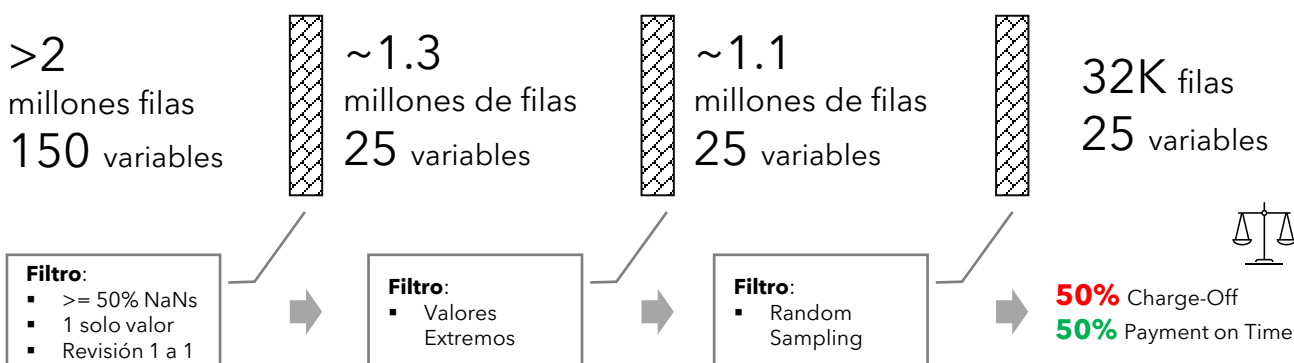
Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
------------------------	----------------------	--------------------------	------------------------	-----------------------

Pre procesamiento de los datos

Del set de datos se eliminó lo siguiente: 1) Columnas con demasiados NaNs, más del 50% 2) Características de solo un valor 3) Lista de variables que probablemente no estarán presentes durante la sesión de negociación. Para el último, no hay otra manera que: Recorrer el proceso paso a paso y preguntar a un experto en la materia o a un súper usuario del proceso. Al final, el análisis fundamental importa.



- La variable destino es `loan_status`, solo se trabajó con valores totalmente pagados y cancelados. Se necesita que el modelo de Machine Learning encuentre la "barrera" entre estos dos resultados. Valores: 'Current', 'Late (31-120 days)', 'InGracePeriod', 'Late (16-30 days)' se ignoran / descartan.
- Revisando todas las características numéricas y construyendo un diagrama de caja para cada una, vemos algunas cosas interesantes como ingresos anuales realmente por encima del promedio. Dado esto, fue necesario deshacernos de los valores atípicos, los ingresos anuales o saldo revolving muy altos. Los valores atípicos son parte de los clientes de UHNW, erroreso Premium Banking / Wealth Management, ergo, podemos deshacernos de estas filas pues no entran dentro de la clasificación de cliente común.
- Finalmente hacemos un conjunto equilibrado muestreando 32K filas (`replace=false`) de ambos segmentos seleccionados de la variable objetivo. ¿Por qué 32 mil?, simple, se usa la fórmula de tamaño de muestra representativa para 2,260,668 registros. Lo anterior al 99% de nivel de confianza, 1% de margen de error y proporción de población del 50%. El resultado, 16,520 registros. Finalmente, tomé 16,520 casos al azar de Payments on Time y 16,520 de Charge-Off, así lo decidí.



Pipelines

No voy a pasar demasiado tiempo aquí, solo algunos comentarios sobre el código. Los Pipeline necesitan información en números, para las variables de destino usamos `LabelEncoder` y para las características usamos `OneHotEncoder` (muchas columnas 1 o 0) o un `OrdinalEncoder` (las mismas columnas diferentes valores numéricos). También necesitamos imputar valores faltantes; esos pueden ser valores frecuentes, media, moda, et al. Siéntanse libres de experimentar aquí. Podemos visualizar los Pipelines como líneas de producción en serie donde se introducen los materiales en bruto y tenemos un carro al final, ahorramos tiempo, esfuerzo y todo es automático.

Descripción
p. 7-13

Solución
p. 14-21


Priorización
p. 22-23

Estrategia
p. 24-26

Monitoreo
p. 27-38

Algoritmo: Importancia de un Pipeline

Los Pipeline en aprendizaje de máquina constan de varios pasos para entrenar un modelo. Éstos son vías iterativas ya que cada paso se repite para mejorar continuamente la precisión del modelo y lograr un algoritmo exitoso. Para crear mejores modelos de aprendizaje automático y obtener el máximo valor de ellos, los pipelines son opciones accesibles, escalables y duraderas, allanando el camino para el almacenamiento de objetos local. El objetivo principal de tener un Pipeline es ejercer control sobre él. Una buena organización hace que la implementación sea más flexible y repetible. **En este caso, utilizaremos un Pipeline para hacer pruebas iterativas con diferentes modelos y decidir cuál de todos arroja una curva de característica operativa del receptor** (Receiver Operating Characteristic - ROC) con mayor área bajo la curva (Area Under the Curve - AUC).



Topografía de nuestro Pipeline

División del Dataframe en
entradas y salidas

```
X = df_group.drop('loan_status',axis=1)
y = df_group['loan_status']
```

Escoge 30% de la muestra
para probar el algoritmo

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3,
random_state=2022)
```

Escala las variable numéricas y
reemplaza vacíos por la media

```
attributes_number = Pipeline(steps=[
    ('null_replacement', SimpleImputer(strategy='mean')),
    ('scaling', StandardScaler())
])
```

Codifica las variable categóricas y
reemplaza vacíos el valor moda

```
attributes_category = Pipeline(steps=[
    ('null_replacement', SimpleImputer(strategy='most_frequent')),
    ('encoding', OrdinalEncoder(handle_unknown='use_encoded_value',
unknown_value = -1))
])
```

Antes de transformar, guarda los
nombres de las columnas

```
columns_number =
X_train.select_dtypes(include='number').columns.to_list()
columns_category =
X_train.select_dtypes(include='category').columns.to_list()
```

Transforma números y categorías

```
attributes_preprocess = ColumnTransformer(transformers=[
    ('number', attributes_number, columns_number),
    ('category', attributes_category, columns_category)
])
```

Codifica la variable objetivo

```
label_encoding = LabelEncoder()
y_train = label_encoding.fit_transform(y_train)
y_test = label_encoding.fit_transform(y_test)
```

Descripción
p. 7-13


Solución
p. 14-21

Priorización
p. 22-23

Estrategia
p. 24-26


Monitoreo
p. 27-38

Exploración de variables importantes. Visualizar coeficientes resultantes de los modelos.




Regresión Lineal

- El periodo del préstamo muestra el mayor impacto de entre todas las características. Las restantes tienen una importancia menor y se parecen mucho entre ellas.




Regresión Logística

- La tasa de interés, cantidad de préstamo, ingresos anuales, ratio deuda-ingreso e hipotecas, resultan ser las características con mayor importancia (coeficientes)




Árbol de Decisión: Regresión

- La calificación crediticia del cliente, tipo de puesto de empleo, lugar en donde vive, ratio deuda-ingreso, balance y tasa de interés entre otras, son características importantes. Las demás tienen cierta amplitud pero no tanta como estas mencionadas.




Árbol de Decisión: Clasificador

- Un caso muy parecido al regresor del árbol de decisión. Aquí la clasificación crediticia obtiene, de igual forma, el mayor coeficiente de importancia, seguido del empleo del cliente.



XGBoost: Clasificador

- De igual forma que el árbol de decisión, XGBoost muestra el mayor coeficiente para la calificación crediticia. El periodo del préstamo es la variable que sigue en importancia.



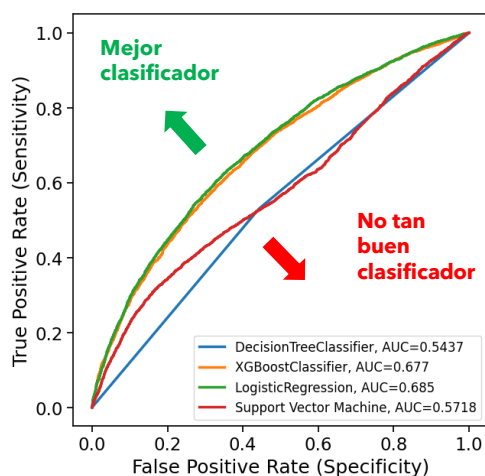
XGBoost: Regresión

- Mismo caso que la parte de XGBoost del clasificador, la calificación crediticia y el periodo de préstamo muestran ser las variables más importantes.

Descripción
p. 7-13Solución
p. 14-21Priorización
p. 22-23Estrategia
p. 24-26Monitoreo
p. 27-38

Selección de un algoritmo

Para la selección de un algoritmo se usó la curva ROC, es una técnica para visualizar, organizar y seleccionar clasificadores en función de su rendimiento. Los gráficos ROC son una herramienta muy útil para visualizar y evaluar clasificadores y son capaces de proporcionar una medida más clara del rendimiento de la clasificación que las medidas escalares, como la precisión, la tasa de error o el costo del error (Fawcett, Tom, 2005).



Elección del mejor modelo

Se eligen 4 posibles modelos, Decision Tree Classifier, XGBoost Classifier, Logistic Regression y Support Vector Machine para ser procesados con el Pipeline anteriormente descrito

Se procesa cada uno de los modelos y se obtienen sus curvas ROC para después ser comparadas gráficamente. Una vez hecho esto, el modelo con la mayor AUC resulta ser: **Logistic Regression**.

Resultados del algoritmo

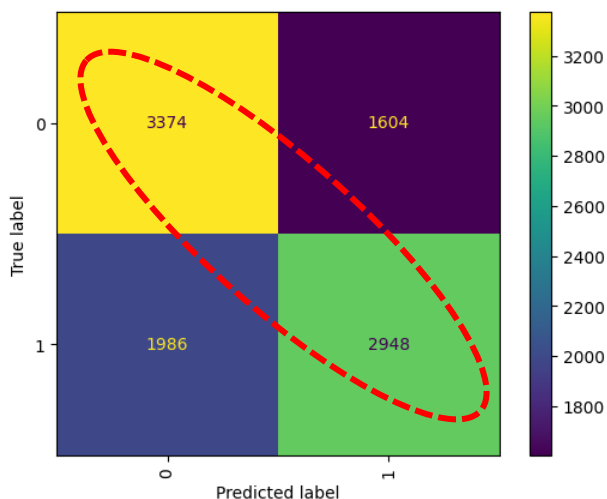
El mejor modelo, **Logistic Regression**, tiene una precisión del 64%, una precisión del 63%, una recuperación entre el 61% y 68% con un F1 score de 63% a 65%

En Matriz de confusión podemos ver la predicción vs el valor real del crédito, es decir el valor predicho por el algoritmo vs el resultado real del cliente (si pagó o no pagó)

1 corresponde a los préstamos que si fueron pagados y 0 a los préstamos que no fueron pagados y se tuvieron que absorber como pérdidas

```
mean accuracy (train): 0.6507142857142857
mean accuracy (test): 0.6420833333333333
```

	precision	recall	f1-score	support
0	0.63	0.68	0.65	3561
1	0.66	0.61	0.63	3639
accuracy			0.64	7200
macro avg	0.64	0.64	0.64	7200
weighted avg	0.64	0.64	0.64	7200



Descripción
p. 7-13

Solución
p. 14-21

Priorización
p. 22-23

Estrategia
p. 24-26

Monitoreo
p. 27-38

Inteligencia Artificial Explicable, una forma de conocer cómo opera el modelo

"SHAP, que significa SHapley Additive exPlanations, es probablemente el estado del arte en la explicabilidad del aprendizaje automático. Este algoritmo fue publicado por primera vez en 2017 por Lundberg y Lee es una forma brillante de realizar ingeniería inversa de la salida de cualquier algoritmo predictivo. En pocas palabras, los valores SHAP se utilizan siempre que tenga un modelo complejo (podría ser un aumento de gradiente, una red neuronal o cualquier cosa que tome algunas características como entrada y produzca algunas predicciones como salida) y desee comprender qué decisiones está tomando el modelo" (Samuele Mazzanti, 2020)

Siguiendo con la misma explicación de Mazzanti, los valores SHAP se basan en los valores de Shapley, un concepto que proviene de la teoría de juegos. Pero la teoría de juegos necesita al menos dos cosas: un juego y algunos jugadores. ¿Cómo se aplica esto a la explicabilidad del aprendizaje automático? Imaginemos que tenemos un modelo predictivo, entonces:


- a) el "juego" es reproducir el resultado del modelo,
- b) Los "jugadores" son las características incluidas en el modelo.

Lo que hace Shapley es cuantificar la contribución que cada jugador aporta al juego. Lo que hace SHAP es cuantificar la contribución que cada característica aporta a la predicción realizada por el modelo.

Explicabilidad Global

En la gráfica de la derecha podemos observar que hay variables que influyen altamente en la predicción "global" del algoritmo. La gráfica muestra de arriba hacia abajo la importancia de las variables, es decir, nos dice qué jugadores son los más importantes al momento de predecir un resultado ya sea positivo o negativo en el pago del préstamo personal. Las variables **más influyentes** son:

- a) Calificación crediticia
- b) Ratio deuda-ingreso
- c) Cuentas hipotecarias
- d) Dónde viven
- e) Finalidad del préstamo
- f) Ingreso anual
- g) Tasa de interés



Descripción
p. 7-13

Solución
p. 14-21

Priorización
p. 22-23

Estrategia
p. 24-26

Monitoreo
p. 27-38

Cuatro casos ilustrativos de explicabilidad local


No Registro: 0

A favor de que pague: Cuenta hipotecaria y su estatus

En contra: Propósito del préstamo y ratio deuda-ingreso

Resultado predicho: No pagará / Resultado real: Si pagó

Caso: Refinanciamiento de tarjeta de crédito, 3 cuentas hipotecarias, deuda-ingreso 23.16%, cliente que se dedica a ensambles (podrían ser industriales)




No Registro: 1

A favor de que pague: Cuenta hipotecaria

En contra: Propósito del préstamo y ratio deuda-ingreso

Resultado predicho: Si pagará / Resultado real: Si pagó

Caso: 6 cuentas hipotecarias, 105k USD anuales de ingreso y un préstamo para consolidación de deuda.




No Registro: 3

A favor de que pague: Calificación crediticia

En contra: Lugar donde vive y cuenta hipotecaria

Resultado predicho: No pagará / Resultado real: No pagó

Caso: Cliente de New Jersey con una calificación C1, renta y tiene 0 cuentas hipotecarias con un ingreso anual de 52k USD




No Registro: 4

A favor de que pague: Calificación crediticia y deuda-ingreso

En contra: Lugar donde vive y cuenta hipotecarias

Resultado predicho: Si pagará / Resultado real: No pagó

Caso: B5 en calificación crediticia, 13.98 en deuda-ingreso, vive en Maryland y no tiene cuenta hipotecaria

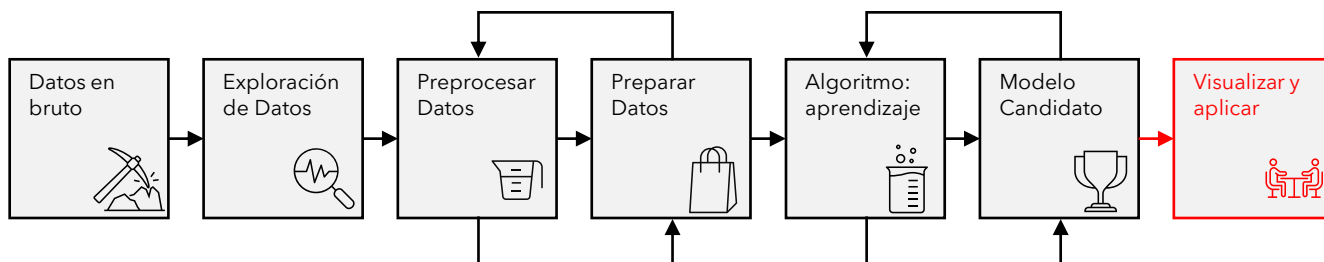


La explicabilidad local nos ayuda a ver caso por caso el porqué el algoritmo asignó un resultado. Siendo así, podemos super personalizar el plan de préstamo para cada cliente o cliente potencial

Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
-------------------------------	-----------------------------	---------------------------------	-------------------------------	------------------------------

Interface de Usuario

Se eligió utilizar Gradio para la interface con la que el algoritmo interactúa con el empleado bancario. Gradio puede estar embebido en Python y permite diseñar la solución en notebooks o en la web. En este caso, primero se exporta el pipeline y posteriormente se carga el modelo en la interface de Gradio para poder ejecutar el algoritmo en el momento de la solicitud de préstamo bancario.



En este caso hay varias formas de ejecutar este algoritmo, una de ellas es hacer un deploy del algoritmo a cada punto de venta que requiera otorgar un préstamo personal. Dado lo anterior, otra forma sería utilizar alguna solución en la nube como Google Cloud Platform para hacer un deployment de 1 sola vez y dar acceso a varias conexiones para que todas utilicen el algoritmo; así se centraliza la ejecución del algoritmo.

Otra herramienta que se puede utilizar es Flask, aunque un banco podría hacer uso de proveedores web para tener su propia aplicación distribuida o usar Google Cloud Platform.

La interfaz de usuario, titulada 'Default Predictor Module', tiene un fondo oscuro. En la parte superior, hay un mensaje: 'Please enter client information to predict -default- or continue allocating the loan'. A la izquierda, hay una sección de 'Información proporcionada por el cliente. Lo registra el empleado' que contiene seis controles deslizantes: 'Loan Amount' (11190), 'Interest Rate' (16.5), 'Installment' (482), 'Annual Income' (70143), 'Debt to Income Ratio' (12) y 'Open Accounts' (5). En el centro, hay un espacio para el 'logo bancario' con una imagen de una mano entregando una tarjeta. A la derecha, hay una 'Sección de instrucciones'. En la parte inferior derecha, hay un panel 'output' que muestra el mensaje: 'Analysis deems the loan: Suitable for AUTHORIZATION', seguido de un botón 'Avisar'. Una caja de texto explicativa indica: 'Resultado del algoritmo. Dados los inputs del cliente el algoritmo recomienda prestar o no prestar al cliente'.

Descripción
p. 7-13Solución
p. 14-21Priorización
p. 22-23Estrategia
p. 24-26Monitoreo
p. 27-38

Priorización según la matriz de impactos de iniciativa de mejora

¿Por qué este proyecto tuvo más prioridad que otros?

Este proyecto, predicción de default crediticio, usa aprendizaje de máquina cuyo uso extensivo en el mercado ha logrado dar buenos resultados tanto al mundo bancario como a otros sectores. El proyecto de default crediticio podría generar valor al banco al permitir una mejor asignación de créditos. Para el cliente, ayudaría a definir un plan adecuado de préstamo que se ajuste a las posibilidades de la persona. Es un proceso que permite mayor rapidez ya que esta automatizado.

Uno de los problemas con mayor impacto al banco es la mora y eso no solamente genera que el pago del cliente se reduzca a cero, también implica aumentar el número de créditos incobrables y por tanto, la reducción de asientos contables que pueden impactar directamente al valor en libros de la empresa. Además de impactar el valor en libros, también puede haber un daño reputacional, ¿les gustaría que su dinero esté en las arcas de un banco que presta sin controles? NO. Lo anterior también podría ser visto como un riesgo operativo del banco, afectar en su reputación y por consiguiente un posible decremento del valor de mercado.

¿Qué tanto tardaría la organización en adaptarse a este proyecto? Relativamente rápido. Para el cliente es un proceso transparente y solo sería más rápido. Para el empleado, solo es llenar información y dar clic en un botón. Quizá, lo más difícil sería revisarlo a nivel privacidad y aceptación del regulador.

Beneficios Esperados

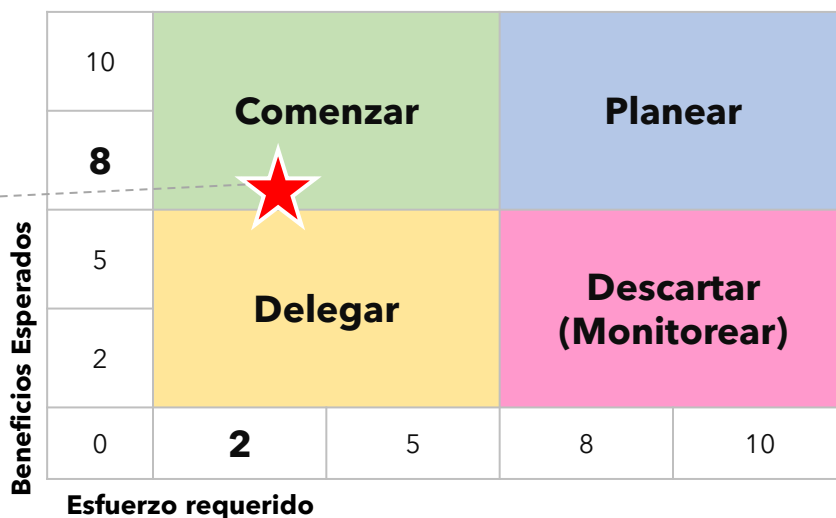
¿Impacta?	Valor	Descripción
Muy alto	10	Múltiples beneficios a individuos al banco y al cliente
Alto	8	Beneficio tangible a banco y a cliente
Moderado	5	Habrà un uso claro del algoritmo
Bajo	2	Uso limitado
Muy Bajo	0	Sin impacto alguno o muy escaso

Esfuerzo Requerido

¿Esfuerzo?	Valor	Descripción
Muy alto	10	Demasiados recursos necesarios y un gasto alto del proyecto
Alto	8	Esfuerzo considerable de las áreas.
Moderado	5	Varios recursos involucrados tanto de operación como revisión
Bajo	2	Recursos abundantes en comparación a las tareas
Muy Bajo	0	Muy pocos recursos requeridos

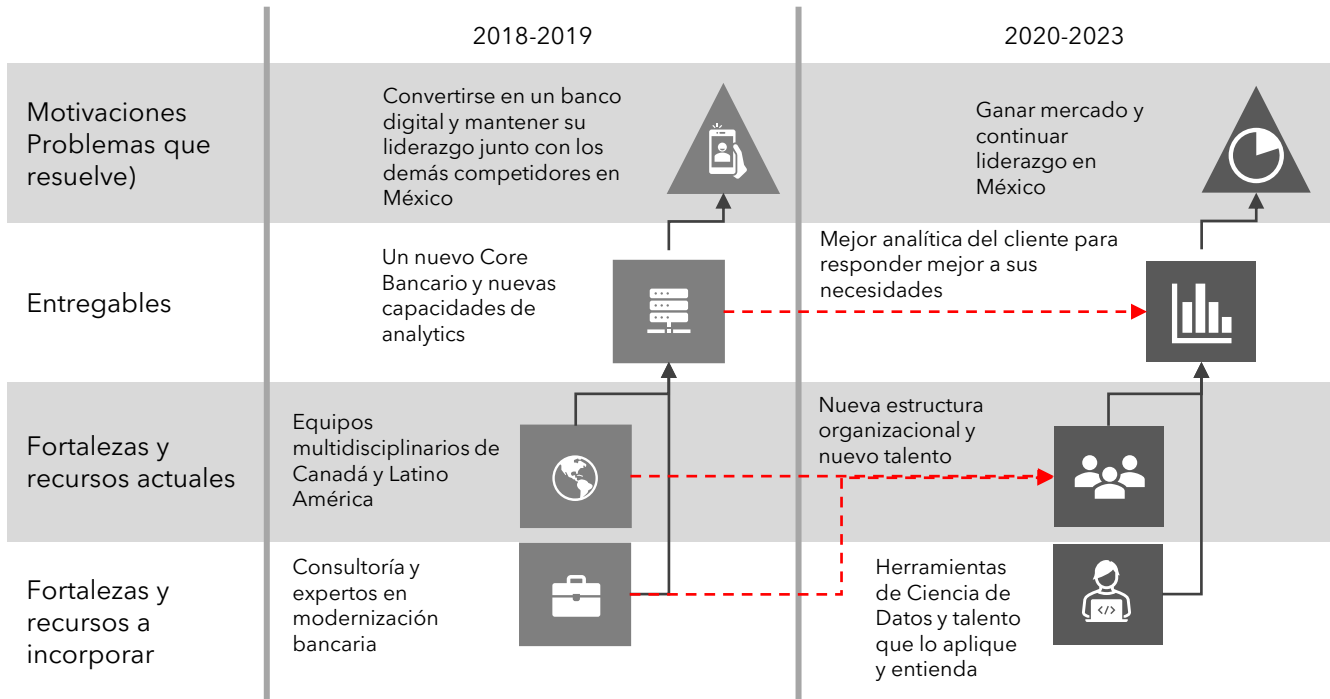
El proyecto está aquí, requiere de pocos recursos para implementarse. En el caso de Banco ya existen plataformas para el uso de Jupyter Notebooks y colaboración. Su beneficio es alto por disminuir el tiempo del proceso de préstamo.

Los otros proyectos del banco se enfocan en transformaciones tecnológicas que requieren muchos recursos y muchos de ellos se colocan en los cuadrantes: Planear o Descartar



Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
------------------------	----------------------	--------------------------	------------------------	-----------------------

Roadmap de innovación/adopción de ciencia de datos en la empresa.

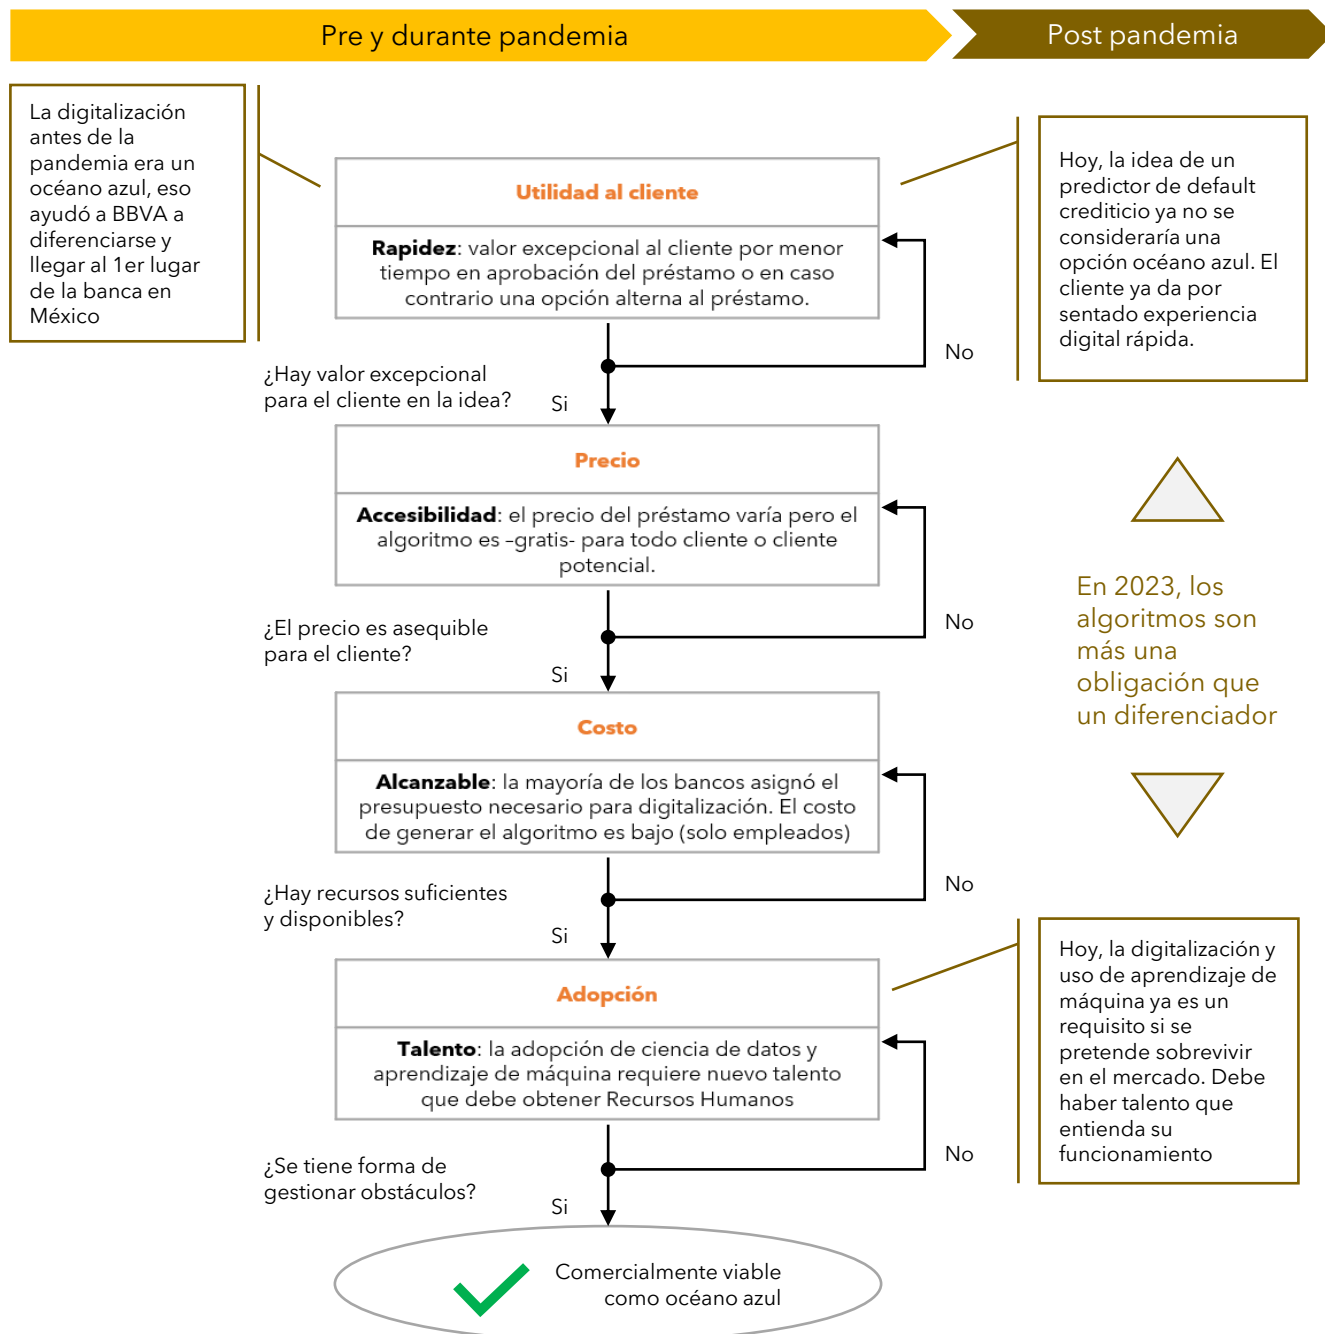


Descripción
p. 7-13Solución
p. 14-21Priorización
p. 22-23Estrategia
p. 24-26Monitoreo
p. 27-38

Estrategia y obstáculos relacionados con la solución propuesta

Secuencia estratégica de Océano Azul

¿Realmente estamos ante una idea de océano azul con el predictor de default crediticio? Originalmente si, hoy es una idea comercial que más que necesaria, es obligatoria para los bancos. El costo para un banco es pequeño, las herramientas ya están disponibles desde hace mucho tiempo y el valor que agrega al cliente y al inversionista era considerable, ya no, ahora es un requerimiento. Veamos la secuencia pre y post pandemia en México de este algoritmo para préstamos:



Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
------------------------	----------------------	--------------------------	------------------------	-----------------------

Matriz de las cuatro acciones

Un algoritmo como este, está íntimamente relacionado con la experiencia del cliente (Customer Experience CX). La implementación de aprendizaje de máquina al proceso de préstamo personal forma parte de la vivencia que el cliente experimenta a través del camino de asignación del préstamo. Es así como el banco podría preguntarse qué debe reducir, qué debe eliminar, qué debe crear y qué debe aumentar para poder atender a las necesidades del cliente.


En su publicación: Customer experience as the new standard - How can banks successfully realign?, Deloitte muestra la importancia de una conexión emocional con los clientes así como tener una variedad adecuada de productos financieros disponibles. Al final Deloitte identifica la experiencia del cliente - CX- como un resultado de la marca, diseño en servicio, interfaz de usuario y todo eso creciendo exponencialmente dada la cantidad de datos en resguardo o disponibles.

$$CX = (Marca + Diseño + UX/UI)^{Datos}$$

Bien, ya tenemos la importancia del algoritmo unida al cliente a través de la experiencia en el proceso de otorgamiento de préstamos. ¿Cómo relacionamos este algoritmo con la matriz de las cuatro acciones? **Fácil, este algoritmo reduce el tiempo de transacción para los clientes y el préstamo personal es parte de la estrategia de "everyday banking", o mejor dicho, estar a lado del cliente en todo las 24/7 para ayudarlo en su quehacer como cliente.** Los siguientes puntos son una estrategia que los bancos pueden adoptar para mantenerse en el mercado de acuerdo con McKinsey en su reporte "The future of banks: A \$20 trillion breakup opportunity"

Eliminar	Aumentar
<ul style="list-style-type: none"> Obsolescencia: Pasos innecesarios en los servicios a clientes Barreras organizacionales que impidan la colaboración ágil Tareas redundantes 	<ul style="list-style-type: none"> Controles de cumplimiento regulatorio Diferenciación de productos Análisis del comportamiento del cliente Everyday Banking (servicios integrados) Investment Advisory Integración entre plataformas de servicio internas
Reducir	Crear
<ul style="list-style-type: none"> Complejidad en procesos de préstamo Silos organizacionales Tiempos de operación para respuestas a clientes Brechas entre talento y requerimiento del mercado 	<ul style="list-style-type: none"> Más conexiones con proveedores y aliados en el sistema financiero Iniciativas cross-selling (PyMEs, fundaciones, loyalty rewards, plataformas AI) Procesos bajo el diseño "accesible", "affordable" y "appropriate" Banking as a Service Cultura emprendedoras en la organización Nueva definición del propósito de la banca

Curva de valor



Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
------------------------	----------------------	--------------------------	------------------------	-----------------------

Adopción de la solución y obstáculos encontrados

No hubo una adopción específica del algoritmo en el banco, en este caso Banco, en su lugar hubo una socialización de las bondades de Ciencia de Datos en el área de riesgos del banco. ¿Por qué transmitir este ejercicio a las áreas de riesgos? La respuesta descansa sobre el objetivo de las áreas a las que se le compartió este documento. Los equipos validan modelos de aprendizaje de máquina de diversas líneas de negocio como Retail y Business Banking. También existe el impacto de la transformación de las operaciones tradicionales a la adopción de Inteligencia Artificial, Big Data y Aprendizaje de Máquina que no solamente forma parte de los objetivos estratégicos de Banco, también del sector bancario en general.

Lo que se espera con este documento es que se adopte internamente el mindset de Ciencia de Datos como un acompañante en las tareas cotidianas del banco para mejorar eficiencia, velocidad y la experiencia de los clientes. El resultado fue bueno, el área de riesgos me incluyó en reuniones de adopción de nuevas tecnologías y pude compartir código con colegas de diferentes áreas, pequeños pasos pero contundentes en la adopción de herramientas de aprendizaje de máquina.

Sobre los obstáculos encontrados, el más grande y difícil de sortear es el acceso a los datos de clientes, dadas las regulaciones locales y la creciente amenaza externa hacia la privacidad de los clientes bancarios, no pude conseguir datos reales de clientes Banco; en su lugar utilicé datos reales de LendingClub para hacer un simil.

Creo que en el futuro, Banco adoptará alguna plataforma similar a Google Cloud Platform para la generación de algoritmos, pipelines y colaboración entre áreas. Lo anterior requerirá de talento y experiencia en temas como el que aborda este documento.

Tabla de experimentación en caso simulado

Hipótesis	Impacto si sale mal	Validación	Prioridad	Descripción	Criterio de evaluación	Resultado	Aprendizaje y mitigación
El algoritmo tendrá una exactitud de al menos 80%	<p>■ Alto</p> <p>■ Medio</p> <p>■ Bajo</p> <p>(Cartera limitada)</p>	<p>■ Alto ←</p> <p>■ Medio</p> <p>■ Bajo</p> <p>(Se valida modelo con set de pruebas)</p>	Validada y de bajo impacto, prioridad media	Correr el algoritmo con 20 casos nunca antes vistos	% Exactitud	Exactitud al 64%	Se requieren más datos de entrada. Se requeriría supervisión humana
El score crediticio es una variable de las más importantes	<p>■ Alto</p> <p>■ Medio</p> <p>■ Bajo ←</p> <p>(Existen más variables)</p>	<p>■ Alto ←</p> <p>■ Medio</p> <p>■ Bajo</p> <p>(Se valida con SHAP)</p>	Igualmente una prioridad media	Utilizar SHAP para observar la explicab. global.	Que el score crediticio quede dentro del top de variables	Score crediticio queda como el 1ro en el top de variables	SHAP puede ayudar a verificar las variables con más impacto en el algoritmo
El uso del algoritmo dará margen positivo	<p>■ Alto</p> <p>■ Medio ←</p> <p>■ Bajo</p> <p>(Afecta de forma directa al margen aunque no mucho)</p>	<p>■ Alto</p> <p>■ Medio ←</p> <p>■ Bajo</p> <p>(Se simulan impactos con datos de la CNBV)</p>	Alta prioridad porque es dinero de clientes y margen para el banco aunque sea una cartera pequeña	Calcular el margen de los 20 casos nunca antes vistos. Usando costo de fondeo y la tasa de interés.	Obtener un margen positivo	Margen positivo a costo de fondeo menor al 6%	El costo de fondeo influye mucho al igual que el poder predictivo. Se requieren más variables y supervisión humana

Descripción
p. 7-13Solución
p. 14-21Priorización
p. 22-23Estrategia
p. 24-26Monitoreo
p. 27-38

Monitoreo y Resultados

Indicadores de Éxito del Proyecto (Key Performance Indicators)

Este proyecto se basa en la predicción del default crediticio, para ello se contemplan **2 tipos de indicadores**, unos que tienen que ver con el **poder predictivo** del algoritmo y otros que tienen que ver con el **impacto económico** al banco. El primer grupo de KPI muestra el uso del algoritmo en información no antes vista y califica su desempeño. El segundo grupo toma las predicciones del algoritmo y evalúa los préstamos comparando ganancias con y sin el algoritmo. A continuación los indicadores con sus definiciones de acuerdo con Google Developers:

Umbral: ● X<80%, ● X ~ 80%, ● X>80%

Accuracy	Precision		Recall		F1	
La exactitud (Accuracy) es la fracción de predicciones que el modelo realizó correctamente	La precisión responde a: ¿Qué proporción de identificaciones positivas fue correcta?		La recuperación responde a: ¿Qué proporción de positivos reales se identificó en forma correcta?		Combina precisión y recuperación	
64% en este modelo	Defaults	Pagos	Defaults	Pagos	Defaults	Pagos
	63%	65%	68%	60%	65%	62%

$$A = \frac{TP + TN}{TP + TN + FP + FN}$$

$$P = \frac{TP}{TP + FP}$$

$$R = \frac{TP}{TP + FN}$$

$$F1 = 2 \frac{Precision * Recall}{Precision + Recall}$$

TP = positivos reales / TN = negativos reales / FP = falsos positivos / FN = falsos negativos

Lejos de la expectativa, este proyecto no cumplió con su objetivo que es predecir atinadamente un default crediticio, es decir al menos un 80%. ¿Qué hacer ahora? Lo que pasaría, en un caso como este, es el despido de toda el área del banco que se encargó de generar el algoritmo. Por otro lado, podría suceder una mentira piadosa donde las unidades de negocio pintan un **OK** en los reportes a la dirección general, todos aplauden y le dan bono al líder de proyecto; claro que esto nunca pasa ¿eh?. Dejando la ficción y el humor de lado, en ninguno de los casos se logra un avance.

Siguientes pasos: Primero, se debe aceptar que el algoritmo solo es capaz de generar una exactitud del 64% y que hay que explorar más, ya sea con nuevas variables como datos biométricos o hacer un screening adicional al cliente, quizá conformar opiniones de conocidos del cliente potencial. ¿Cómo hace Netflix para recomendarnos justo la serie que nos cautiva? ¿Cómo hacen Facebook e Instagram para mantenernos todo el día en la pantalla? ¡Eso!, escucharnos, meter esa información y enriquecer el algoritmo para poder hacer predicciones más poderosas.

Mismo caso aquí, los bancos tienen que hiper personalizar el servicio a clientes y clientes potenciales, empujar que los datos de las personas sean cada vez más accesibles y recolectados frecuentemente, casi como el sistema social chino. Lo anterior suena macabro pero bajo regulaciones adecuadas que promuevan los valores humanos se puede encontrar un justo medio.

Siguiente grupo de indicadores: Ahora que los indicadores de desempeño del algoritmo se conocen. ¿Cómo se vería el banco si se aplica el algoritmo en los préstamos personales? ¿Perderíamos dinero por su exactitud tan baja? Para responder lo anterior primero tenemos que ver a los préstamos muy de cerca, si el banco genera un préstamo debe tener un fondo de dónde sacar dinero para prestar. Lo ideal, es que el costo del fondeo sea cero, pero en algunos casos el costo del fondeo es una tasa preferentemente menor al interés pagado por el cliente. De lo anterior, un préstamo genera ganancias para el banco porque puede el costo de prestar un peso es menor al interés generado por prestar ese mismo peso. Entonces, lo que debemos hacer es tener en cuenta la tasa de interés, la tasa que paga el banco por los fondos y hacer un aproximado del margen obtenido por el préstamo.

Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
-------------------------------	-----------------------------	---------------------------------	-------------------------------	------------------------------

Un indicador de éxito que depende mucho del costo de fondeo

Veamos como vamos en el conteo de indicadores, hasta ahora tenemos 4 indicadores de éxito relacionados con el desempeño del algoritmo. Pondremos 1 más, relacionado al beneficio económico



Accuracy	Precision		Recall		F1		Margen
La exactitud (Accuracy) es la fracción de predicciones que el modelo realizó correctamente	La precisión responde a: ¿Qué proporción de identificaciones positivas fue correcta?		La recuperación responde a: ¿Qué proporción de positivos reales se identificó en forma correcta?		Combina precisión y recuperación		Margen en MXN millones dado el uso del algoritmo
64% en este modelo	Defaults	Pagos	Defaults	Pagos	Defaults	Pagos	<p>● Margen Positivo</p> <p>● Margen Negativo</p>
	63%	65%	68%	60%	65%	62%	<p>● Positivo</p> <p>Con costo de Fondeo menor o igual al 7.5%</p>

Análisis What if en Excel: Para poder analizar el desempeño económico debemos hacer algunas suposiciones sobre el resultado de los préstamos personales. Nuestros supuestos son:

- 1) Selección de 9,912 préstamos personales (no usados en el entrenamiento y de la base de LendingClub)
- 2) Ninguno de estos préstamos se utilizó en el entrenamiento del algoritmo y corresponden a diferentes años
- 3) Se hace uso de un tipo de cambio de 18.05 MXN/USD para convertir USD a pesos mexicanos
- 4) Si el cliente incurre en un DEFAULT, deja de pagar desde el mes 6 hasta final de año (muy, muy, vencido)
- 5) Se considera solo margen, es decir, intereses generados - costo de fondeo (Se asume mismo costo para todos)
- 6) Costo de fondeo variando desde TIE 11% hasta descender a 0% como en el caso de depósitos de nóminas
- 7) La tabla que generó los escenarios lo hizo con base en cada una de las tasas de fondeo del rango anterior

Análisis de escenarios paso a paso

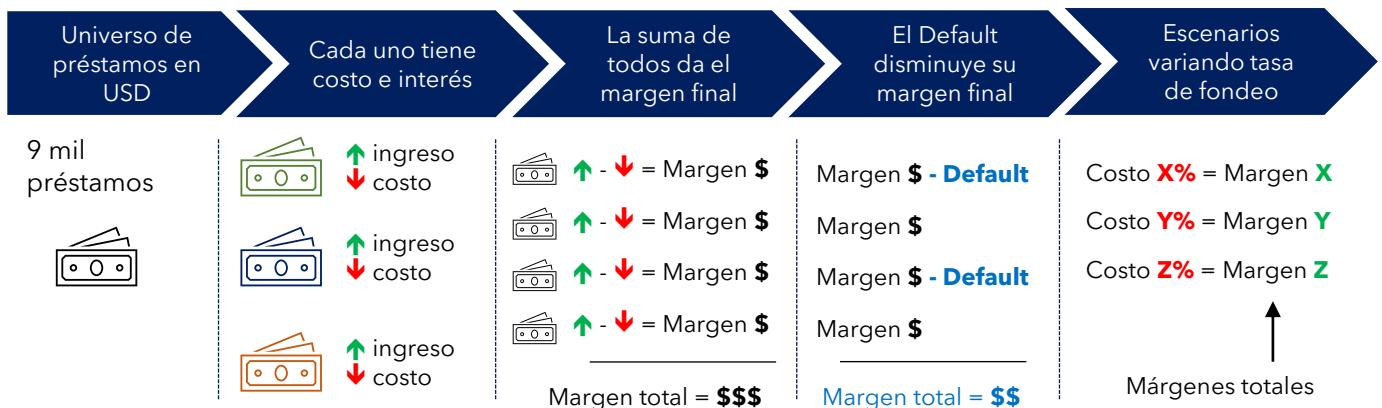


Tabla de resultados del análisis -what if- en Excel



Tasa de fondeo	11%	9.5%	7.5%	0%
Sin algoritmo	↓ 35 millones	↑ 2 millones	↑ 54 millones	↑ 246 millones
Con algoritmo	↓ 34 millones	↓ 19 millones	↑ 1 millones	↑ 77 millones
Conclusiones	Existe menos pérdida si se utiliza el algoritmo	No hay razón para usar el algoritmo	Ambos generan margen. El algoritmo muestra menor ingreso porque no solo filtra defaults, también detiene préstamos que podrían pagarse	

Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
-------------------------------	-----------------------------	---------------------------------	-------------------------------	------------------------------

Impacto en los estados financieros ¿En dónde mirar el resultado del algoritmo?

El beneficio o impacto adverso no puede ser muy grande ya que el algoritmo solo se concentra en una parte pequeña de todos los productos financieros del banco. En este caso solo consideramos los préstamos personales. Considerar que hay más productos como tarjetas, hipotecas, préstamos para automóviles, seguros, etc. Veamos cómo se ve el estado de resultados y el balance del banco de acuerdo con la CNBV.

Reportes financieros de acuerdo con la CNBV en su sección de Banca Múltiple

Estado de Resultados

	Ingresos por intereses
	Gastos por intereses
Margen financiero (Net Interest Income)	
	Estimación preventiva para riesgos crediticios (Provisions for credit loss)
Margen financiero ajustado por riesgos crediticios	
	Neto de comisiones y tarifas pagadas
Ingresos totales de operación	
	Gastos de administración
Resultado de la operación (Net Interest Before Taxes)	
	Impuestos
Resultado neto (Net Interest After Taxes)	

Activo

Pasivo

Efectivo y equivalentes en efectivo	Captación Tradicional - Plazo - Vista - Cuenta global captación sin movimientos
Inversiones e instrumentos financieros	
Créditos comerciales	Préstamos interbancarios y otros
Créditos a entidades financieras	- Corto plazo - Largo plazo - Exigibilidad Inmediata
Créditos a gobierno	Operaciones con instrumentos financieros y derivados
Créditos al consumo	Otras cuentas por pagar
Créditos a vivienda	Instrumentos financieros que califican como pasivo
Estimación preventiva de riesgo crediticio	Otros pasivos
Otras cuentas por cobrar	Capital Contribuido
Bienes adjudicados	Capital Ganado
Otros	Participación no controladora

Impacto en Estado de Resultados

El proyecto de predicción de default en préstamos personales tiene un impacto en el **Estado de Resultados a través del margen financiero**. Si el algoritmo predice eficazmente si un cliente pagará o no un crédito entonces se podrán asignar mejores créditos y por tanto mejorar el margen.

Impacto en Balance del Banco

Como los préstamos personales son a personas físicas el algoritmo **impactaría directamente en la parte de créditos comerciales subiendo o reduciendo la cartera vigente y vencida**. También, dependiendo de la efectividad del algoritmo habría un impacto en la **Estimación preventiva de riesgo crediticio**. Finalmente, también se tendrían que ajustar los pasivos para mantener el balance contable.

Ética

de la

Ciencia de Datos


Se analiza, a través de un lente ético, el ejercicio de predicción de defaults crediticios con una base real y pública de clientes Estadounidenses, para ilustrar una forma más segura de prestar dinero a clientes bancarios.

Antecedentes y Contexto del Proyecto:

Banxico ha impulsado la implementación de las Normas Internacionales de Información Financiera en los bancos para la clasificación de la cartera crediticia en etapas, según el nivel de riesgo y deterioro de la misma, entre otras bondades. Dada la implementación reciente de estas normas (IFRS9) este proyecto pretende ayudar en la predicción de defaults crediticios para evitar prestar a individuos que pudieran incrementar la cartera vencida (vencida o Etapa III).

Propuesta y Justificación

Como se usan técnicas de Machine Learning para generar un modelo predictivo en la asignación de créditos a personas físicas, es importante mitigar riesgos relacionados a la privacidad y discriminación a través de un marco de diseño ético.



Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
-------------------------------	-----------------------------	---------------------------------	-------------------------------	------------------------------

Aspectos éticos en los datos y algoritmos utilizados

Un vistazo al statu quo: discriminar podría tener un efecto positivo

Según Stephanie Kelley y otros autores de Harvard Business Review. **Quitar datos demográficos puede empeorar la discriminación derivada de la Inteligencia Artificial.** El interés por la inversión en algoritmos de aprendizaje de máquina continúa una mayor eficiencia empresarial (30% o más, según McKinsey), sin embargo, el uso de modelos y datos individuales conlleva algunos riesgos éticos. Históricamente, para prevenir decisiones discriminatorias, los datos confidenciales, como la raza, el género y la edad individuales, se han excluido del acceso a préstamos, la admisión a la universidad y la contratación.

El Foro Económico Mundial cita el desempleo, la desigualdad, la dependencia humana y la seguridad entre sus principales riesgos de usar inteligencia artificial y el aprendizaje de máquina. El mayor riesgo ético en la práctica es la discriminación.

En las prácticas de gestión de riesgos de una empresa, el resultado final es el mismo; las empresas rara vez tienen acceso o utilizan datos confidenciales para tomar decisiones que afectan a las personas. Lo anterior, se hace para ir en sincronía con las leyes contra la discriminación (como la **exclusión de datos de raza y género de las solicitudes de préstamos no hipotecarios de los consumidores** en los Estados Unidos debido a la Ley de Igualdad de Oportunidades de Crédito)

Esto se hizo evidente en 2019 cuando Apple Card enfrentó acusaciones de discriminación de género a pesar de no haber utilizado datos de género en el desarrollo de sus algoritmos de ML. Paradójicamente, esa resultó ser la razón del trato desigual de los clientes. El fenómeno no se limita al espacio de préstamo. Consideremos un proceso de **toma de decisiones de contratación** como en Amazon, donde se tenía como objetivo utilizar un algoritmo de aprendizaje de máquina.

Uso ético de algoritmos (blog Harvard Business School)

Como los algoritmos están escritos por humanos, el sesgo puede estar intencionalmente o no presente. Los algoritmos sesgados pueden causar graves daños a las personas.

En Data Science Principles, Sweeney describe las siguientes formas en que el sesgo puede infiltrarse en sus algoritmos:

- **Entrenamiento:** Un conjunto de datos no representativo puede hacer que su algoritmo favorezca algunos resultados sobre otros.
- **Código:** Aunque cualquier sesgo presente en su algoritmo es involuntario, no descarte la posibilidad de que haya sido escrito específicamente para producir resultados sesgados.
- **Entradas:** Los algoritmos también aprenden de las entradas de los usuarios. Como tales, pueden verse influenciados por comportamientos sesgados. Por ejemplo, una plataforma de búsqueda de empleo donde los gerentes de contratación seleccionan constantemente candidatos masculinos blancos para roles específicos, el algoritmo aprenderá y ajustará y solo proporcionará listados de trabajo a candidatos masculinos blancos en el futuro.
- **Principios.** "Usar evaluadores humanos en cada paso del proceso de ciencia de datos, asegurarse de que los datos de entrenamiento sean verdaderamente representativos de las poblaciones que se verán afectadas por el algoritmo, e involucrar a las partes interesadas y otros científicos de datos con diversos antecedentes puede ayudar a hacer mejores algoritmos"

Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
------------------------	----------------------	--------------------------	------------------------	-----------------------

Principios éticos: 8 preocupaciones éticas más importantes del proyecto

Privacidad

El algoritmo para predecir el default crediticio incluye **información personal y sensible de clientes**. Datos que los bancos deben cuidar y evitar su vulnerabilidad conforme a La Ley Federal de Protección de Datos Personales en Posesión de los Particulares (**LFPDPPP**). Entre otros requisitos, el banco debe cumplir con el **aviso de privacidad** definido en el artículo 16 de dicha ley.

Responsabilidad

La LFPDPPP en su **capítulo XI indica las sanciones** derivadas del tratamiento indebido de datos personales por parte del tercero.

El banco deberá observar los principios de licitud, consentimiento, información, calidad, finalidad, lealtad, proporcionalidad y responsabilidad, previstos en la Ley (**Artículo 6**).

Seguridad y protección de la información

De acuerdo con el **artículo 19** de la LFPDPPP, todo responsable que lleve a cabo tratamiento de datos personales deberá **establecer y mantener medidas de seguridad administrativas**, técnicas y físicas que permitan proteger los datos personales contra daño, pérdida, alteración, destrucción o el uso, acceso o tratamiento no autorizado.

Transparencia y características explicables

Los bancos en México deben ajustarse a la **Ley de Transparencia y Ordenamiento de los Servicios Financieros**. Se consideran comisiones y cuotas, disposición y otorgamiento, tarjetas, sanciones y otros.

En cuanto a características explicables, este proyecto pretende utilizar **Shapley Values(en SHAP)** para explicar caso por caso del resultado del modelo.

Justicia y no discriminación

En su **artículo 17**, la Ley de Transparencia y Ordenamiento de los Servicios Financieros define acto discriminatorio a:

“Cualquier acto que limite, restrinja o impida a cualquier persona **en igualdad de condiciones la contratación de algún producto o servicio** cumpliendo con los requisitos previos señalados por las Entidades.”

Control Humano

La práctica de auditoría de Data y Analytics está tomando relevancia en el mercado. Las **Big 4** han incluido dentro de sus servicios de **Audit & Assurance** la parte de Audit data & analytics (ej. KPMG).

Sin embargo, es un punto debatible, hay algo de error humano que puede contagiar al proceso de control del modelo y su mantenimiento. Siempre debe haber una buena práctica como base de análisis.

Responsabilidad profesional

En la práctica profesional financiera hay muchos ejemplos de la responsabilidad profesional, por ejemplo: **Global Investment Performance Standards (GIPS)** que contiene principios éticos para la prestación de servicios.

Dado lo anterior, es entendible que **deba de haber un símil para una práctica de IA o ML en el sector bancario**, al menos, en políticas internas.

Valores humanos

Es bueno tomar una posición siempre, en este caso podríamos usar la **ética normativa** y dentro de la misma considerar la **ética deontológica** de Immanuel Kant.

Con lo anterior la generación de modelos podría seguir un “actuar de acuerdo a una máxima que se pueda considerar ley universal” Dado el caso: Hacer un modelo en pro del mayor bien, común entre cliente y banco

Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
-------------------------------	-----------------------------	---------------------------------	-------------------------------	------------------------------

Criterios y principios a cumplir dentro del marco regulatorio

Con seguridad, los bancos cuentan con códigos de ética y lineamientos de comportamiento ya que México tiene un marco legal que regula a las entidades financieras. En la **Circular Única de Bancos en su artículo 142** sobre los objetivos del Sistema de Control Interno y los lineamientos para su implementación se menciona la relevancia del **código de conducta y código de ética**.

Para fines ilustrativos, podemos tomar el caso de Banco Inverlat en México (institución donde laboro actualmente). Un banco con raíces en Canadá y que tiene presencia en diferentes países, debe atender a distintas regulaciones y requerimientos territoriales. Por ejemplo:

- **En Estados Unidos:** Federal Reserve Board of Governors (FRB), Office of the Comptroller of the Currency (OCC), Federal Deposit Insurance Corporation (FDIC), y Consumer Financial Protection Bureau (CFPB)
- **En Canadá:** Office of the Superintendent of Financial Institutions (OSFI)
- **En México:** Comisión Nacional Bancaria y de Valores, Banco de México, MexDer, entre otros
- **Leyes en México:** Localmente se tienen la Ley Federal de Protección de Datos, la Circular Única de Bancos y la Ley de Transparencia y Ordenamiento de los Servicios Financieros.

Análisis de riesgos y beneficios

▪ Stakeholders:

Clientes	Regulador	Inversionistas	Empleados	Gerencia Alta
				
Se benefician de la aplicación de la ley en el modelo predictivo de ML. La transparencia otorgar créditos genera confianza y una relación sólida banco y cliente.	El apego del banco a la ley vigente y las buenas prácticas definidas por las entidades reguladoras evitan sanciones al banco derivado de una mala aplicación del algoritmo de ML.	La ética da retornos económicos. Ayuda a evitar sanciones y mantener buena reputación ante el mercado que puede traducirse en mayores dividendos.	Al banco le conviene un buen desempeño y control del algoritmo y eso es traducido en utilidades, bonos y la permanencia del empleado en la institución.	Es aquí donde el conflicto enardece. A veces el tratamiento ético no empalma con los objetivos de plazo inmediato y existe la prueba del ácido entre actuar bien o actuar para lograr el objetivo. Lo anterior reta a la dirección general entre objetivos sostenibles y los resultados rápidos con bases endebles.

Descripción
p. 7-13Solución
p. 14-21Priorización
p. 22-23Estrategia
p. 24-26Monitoreo
p. 27-38

Evaluación de Impactos del uso del algoritmo predictivo

Definiremos los criterios a evaluar de la siguiente manera: 1) severidad de la falla 2) probabilidad de que ocurra un evento y 3) posibilidad de detección de un problema. Además un marco para evaluar beneficios y riesgos como sigue:

Beneficios

¿Impacta?	Valor	Descripción
Muy alto	10	Múltiples beneficios a individuos, organización y sociedad
Alto	8	Beneficio tangible a individuos, organización y sociedad
Moderado	5	Habrà un uso claro del algoritmo
Bajo	2	Uso limitado para individuos, organización y sociedad
Muy Bajo	0	Sin impacto alguno o muy escaso

¿Ocurre?	Valor	Descripción
Muy alto	10	Muy seguramente pasará
Alto	8	Altamente probable que ocurra
Moderado	5	De alguna forma puede pasar
Bajo	2	Hay escasas probabilidades
Muy Bajo	0	La probabilidad de ocurrencia es demasiado baja

Riesgos

¿Impacta?	Valor	Descripción
Muy alto	10	Múltiples riesgos a individuos, organización y sociedad
Alto	8	Riesgo tangible a individuos, organización y sociedad
Moderado	5	Habrà un riesgo claro del algoritmo
Bajo	2	Riesgo limitado para individuos, organización y sociedad
Muy Bajo	0	Se puede considerar sin riesgo alguno

¿Ocurre?	Valor	Descripción
Muy alto	10	Muy seguramente pasará
Alto	8	Altamente probable que ocurra
Moderado	5	De alguna forma puede pasar
Bajo	2	Hay escasas probabilidades
Muy Bajo	0	La probabilidad de ocurrencia es demasiado baja

Algoritmo en default crediticio: Combinar beneficios contra impactos

Un algoritmo como este puede traer un beneficio moderado pues **no solamente rechaza posibles defaults, también rechaza posibles créditos**, el alcance **está limitado a los clientes del banco**. En cuanto a riesgo, podemos considerarlo bajo, pues se limita a un grupo reducido de individuos y en casos muy extremos el **escrutinio regulatorio sería reducido**.

¿Qué tanto impacto positivo tiene usar el algoritmo?

Medio: Beneficia en evitar cuentas morosas pero también y filtra cuentas que pueden pagar.

	Frecuencia					Beneficio				
	+ Bajo	Bajo	Med.	Alto	+ Alto					
+ Alta	●	●	●	●	●					
Alta	●	●		●	●					
Med.	●	●	●	●	●					
Baja	●	●	●	●	●					
+ Baja	●	●	●	●	●					

¿Qué tanto riesgo tiene usar el algoritmo? **Bajo:** Es



poco probable que del algoritmo se extrapole información del cliente (Riesgo a la privacidad).

	Frecuencia					Riesgo				
	+ Bajo	Bajo	Med.	Alto	+ Alto					
+ Alta	●	●	●	●	●					
Alta	●	●	●	●	●					
Med.	●	●	●	●	●					
Baja	●	●	●	●	●					
+ Baja	●	●	●	●	●					

Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
-------------------------------	-----------------------------	---------------------------------	-------------------------------	------------------------------

Matriz combinada de beneficios contra riesgos

Con las tablas anteriores podemos colocar el riesgo y el beneficio en una forma combinada donde podemos definir si el algoritmo debe ser publicado, usarse con acceso limitado o completamente abierto. En este caso resulta ser un **algoritmo de acceso limitado**.

	Beneficio 					Riesgo 
	+ Bajo	Bajo	Med.	Alto	+ Alto	
+ Alto	Abierto	Abierto	Limitar acceso	Revisar	Revisar	
Alto	Abierto	Limitar acceso	Limitar acceso	Revisar	Revisar	
Med.	Limitar acceso	Limitar acceso	Revisar	Revisar	No publicar	
Bajo	Limitar acceso	Revisar	Revisar	No publicar	No publicar	
+ Bajo	Revisar	Revisar	No publicar	No publicar	No publicar	

Marco para el análisis de riesgo a la privacidad

Ciertamente el análisis del algoritmo arroja un riesgo bajo en general, pero no es la única parte que debemos de analizar. Nuestro algoritmo de predicción de fraude se alimenta de datos de clientes cuyos datos son principalmente Información Personal Identificable (PII por sus siglas en inglés). Además, el flujo de datos también es un proceso delicado pues en ese caso se tendría que enmascarar datos sensibles - confidenciales - del banco. El caso del procesamiento, muchos algoritmos de ML suelen ser -cajas negras- y explicarlos requiere de técnicas similares al uso de Shapley-Values.

Mapeo de componentes LINDDUN, tipos de riesgo y dónde están.

¿Por qué utilizar esta metodología en el diseño de la predicción de defaults crediticios? LINDDUN es una metodología de modelado de amenazas de privacidad que ayuda a los analistas a obtener y mitigar sistemáticamente las amenazas de privacidad en arquitecturas de software. LINDDUN proporciona soporte para guiar a los diseñadores a través del proceso de modelado de amenazas de una manera estructurada.

En la matriz de la derecha podemos ver que el **riesgo más notorio lo podemos ver en el inventario de información**. Lo anterior es lógico ya que la mayoría de la información guardada por el banco tiene información que puede identificar al individuo como cliente del banco y vulnerar su privacidad en caso de mal uso de la data.

Riesgos potenciales a privacidad	Flujo de Datos (Data Flow)	Inventario (Data Storage)	Proceso (Process)
Relacionar datos económicos (Link)		X	
Identificar a la persona (Identifiable)		X	
Transparentar en resultados (Non-repudiation)			X
Detectar un error o riesgo Detectable	X	X	
Fuga de información (Disclosure and Unawareness)		X	X
Incumplir con regulador (Non-compliance)	X	X	X

Descripción
p. 7-13Solución
p. 14-21Priorización
p. 22-23Estrategia
p. 24-26Monitoreo
p. 27-38

Control humano del sistema de otorgamiento de crédito

Objetivos humanos

Prestar dentro de rangos estipulados, prestar a tasas de mercado, competitivas pero dentro de mercado. Prestar solo si cumple la solvencia mínima definida por el humano.

No discriminar a las personas como lo estipulan las leyes que rigen y regulan a las instituciones bancarias

Preservar autonomía humana

Un humano debe verificar la decisión. Puede que un comerciante de comida no tenga historial crediticio y sin embargo tiene muchísimo dinero. Por otro lado, algún importante ejecutivo de empresa que tenga un historial impecable pero en cierto momento su deuda es tan grande que seguramente no pagará

Responsabilidad humana

La responsabilidad humana reside en el gerente de crédito en la sucursal o en el Call Center. También en el responsable del diseño y el entrenamiento continuo. Al final existen diferentes tipos de necesidades conforme a las edades, hoy, las nuevas generaciones no quieren tener una casa, quieren rentar.

Control del sistema

Intervención humana en la configuración inicial, mantenimiento y entrenamiento frecuente, ajustar a casos como Babyboomers, X-Gen, Millenials, Centenials.

Durante la generación del crédito en las sucursales.

Un ser humano, al final tiene que ser el Accountable, un sistema no responderá a la organización por cualquier variación del resultado.

Hacer sinergia con la inteligencia artificial



Descripción p. 7-13	Solución p. 14-21	Priorización p. 22-23	Estrategia p. 24-26	Monitoreo p. 27-38
-------------------------------	-----------------------------	---------------------------------	-------------------------------	------------------------------

Datos y modelos que ayudaron a generar el algoritmo

Referirse a la sección de “Solución” de este documento, allí se hace mención a los algoritmos, datos, interfaces y AI explicable.

Uso del algoritmo: Análisis de Fallas y Efectos

Es buena práctica identificar los requerimientos técnicos, operacionales y organizacionales de un sistema para poder prever riesgos, identificar estancos, proponer controles y generar indicadores apropiados para monitoreo. Aquí vale la pena generar un análisis de fallas y efectos (**FMEA** - Failure Mode & Effects Analysis). Lo anterior ya que la predicción de default crediticio se diseña junto con planes de control y objetivos de mejora.

Etapas del proceso	Modo de falla	Efecto de falla	Sever.	Causas de falla	Prob.	Controles	Detec.	Número Prioridad de Riesgo
Ejecución del algoritmo para la predicción del default en crédito	El cliente no da datos correctos	Algoritmo no trabajará adecuadamente	10	Decisión del cliente de no decir la verdad	7	Filtro adicional	7	490
				Error del empleado al registrar datos	5	Entrenar a empleado	5	250
	No está disponible el sistema	El algoritmo no puede usarse	5	Falla en sistema	5	Soporte IT	3	75
				El empleado no sabe utilizarlo	5	Entrenar a empleado	3	75
	El resultado de la predicción del algoritmo es distinta a la realidad	El cliente pierde un cliente que puede pagar	7	El algoritmo se entrenó con pocas variables discriminantes	7	Re calibrar algoritmo	7	343
				El algoritmo no se ha reentrenado recientemente	3	Re entrenar algoritmo	3	63
		El cliente no paga	10	Falso positivo del algoritmo	7	Filtro adicional	5	350

Como podemos ver, el análisis del diseño de un algoritmo de predicción de default crediticio requiere de observar muchas y distintas partes. **Los requerimientos técnicos no solamente versan sobre el dominio de software y ciencia de datos, también sobre el marco legal de los reguladores de bancos en México.** En cuanto a lo organizacional, es preferible tener un área de riesgos específica para atender riesgos operativos, legales, privacidad y de tecnología que sirvan como filtros para una iniciativa como esta. En cuanto a lo operacional, es bueno generar indicadores de desempeño del algoritmo que estén bajo la vigilia del área de operaciones del banco.

Recomendaciones y comentarios finales: ¿Cómo auditar?

Para muchas empresas el término Integrated Risk Management Solution (IRM) implica una gran inversión, pero también una ventaja competitiva. Auditar a través de un IRM es fácil y rápido. Estas suites ayudan a las compañías a simplificar el proceso de revisión, automatización e integración de iniciativas a sus objetivos estratégicos. Entre las soluciones recomendadas por Gartner - consultoría especializada en rankings - están ServiceNow, SAP Risk Management, LogicManager, Archer Suite, Refinitiv Connected Risk y mi elección personal Open Pages de IBM. Esta última, de acuerdo con Gartner, es una plataforma versátil y poderosa para el gobierno y cumplimiento de tareas relacionadas al riesgo corporativo. Open Pages ayuda con herramientas de análisis, trazabilidad y es altamente customizable.

Descripción
p. 7-13

Solución
p. 14-21

Priorización
p. 22-23

Estrategia
p. 24-26


Monitoreo
p. 27-38

Auditoría de los algoritmos: Uso de Open Pages de IBM

De acuerdo con Brian Jie (Gartner, 2019) Una implementación de un IRM reduce riesgos aislados y permite la toma de decisiones empresariales dinámicas a través de correlaciones de datos de riesgo y procesos de riesgo compartidos. Las soluciones Integrated risk management (IRM) combinan la tecnología, procesos y datos para permitir la simplificación, automatización e integración de la gestión de riesgos estratégicos, operativos y de TI en toda la empresa. Para comprender y gestionar todo el alcance del riesgo, las organizaciones requieren una visión integral de las unidades de negocio y las funciones de riesgo y cumplimiento, así como de los principales socios comerciales, proveedores y entidades subcontratadas. Con lo anterior, vemos que un IRM no solamente toca la estrategia de la organización, también los recursos técnicos, de gobierno, organizacionales y de procesos.



¿En qué beneficiaría escoger este IRM para la auditoría algorítmica de la empresa y no solamente para este caso en particular?



- Industria: Su principal industria son los bancos ~27% de todas sus instalaciones son allí.
- Geografía: Distribuida equitativamente ~25% en cada región como Latinoamérica, Norte América, Asia Pacífico y Europa Medio Oriente y África.
- YouTube: Vastos recursos y tutoriales gratis para el aprendizaje.
- Gestión: Utiliza usuarios que pueden tener diferentes roles y responsabilidades
- Analítica: Dashboards embebidos

Ética de la Ciencia de Datos: Comentarios de Cierre

Es cierto que una inversión para la auditoría algorítmica puede ser onerosa para las empresas, pero los beneficios pueden ser mayores. Cumplir con los requisitos regulatorios del mercado tanto globales como locales asegura la resiliencia de las compañías y su sostenibilidad en el tiempo. Adicional a lo anterior, el cumplimiento y transparencia de una compañía suelen ser muy bien recibidas por los clientes tanto actuales como potenciales, esto le da el valor reputacional que puede diferenciar a una empresa del resto de sus competidores.

El algoritmo de predicción de default crediticio tiene varias aristas para el análisis, desde el control humano en su generación, entrenamiento y aplicación hasta el marco regulatorio que influye en su funcionamiento. En México hay tres pilares del cuerpo regulatorio para algoritmos como este: 1) Ley Federal de Protección de Datos en Posesión de Terceros 2) Circular Única de Bancos y 3) Ley de Transparencia y Ordenamiento de los Servicios Financieros.

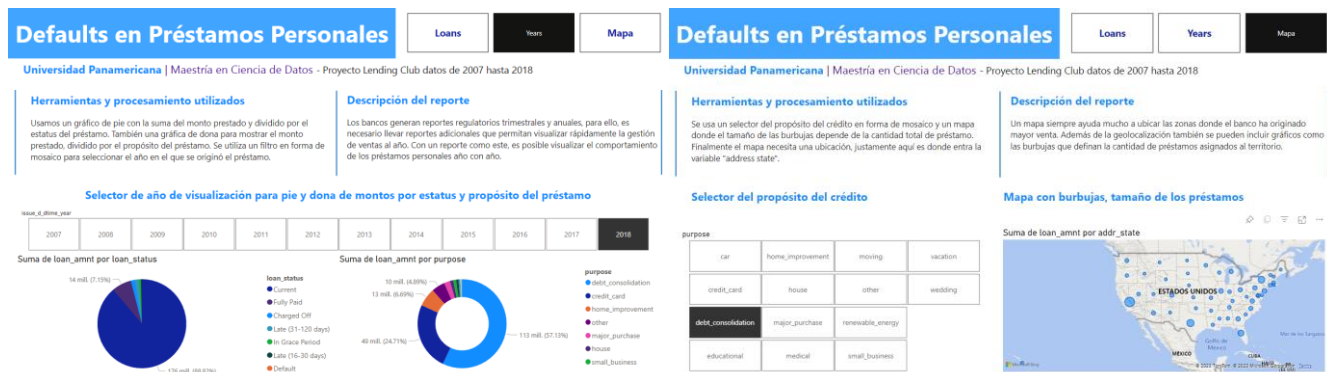
Hacer algoritmos y utilizarlos en una empresa parece fácil, pero su impacto para la sociedad requiere de mucha más atención pues existe un marco regulatorio.

Extras: Dashboards en PowerBi

Visualización

El algoritmo puede ayudar a la organización bancaria en sus primeras filas, es decir, en sucursales o inclusive en atención al cliente. La visualización de los datos en dashboards PowerBi puede ayudar a aquellos que toman decisiones, a ver el comportamiento de los datos. En este caso, se usó PowerBi para poder ver los préstamos y su concentración.

Se pueden crear visualizaciones muy diversas en este programa, desde gráficos de frecuencias para detectar outliers hasta paretos para conocer qué clase de variables aportan el 80% de un resultado. Otra de las bondades de PowerBi es que se pueden crear varias páginas y crear un navegador de forma simple y rápida para navegar entre los reportes. La capacidad de este software de crear mapas y relacionarlos con datos útiles ayuda a tener un reporte visual por territorio y filtrar mapas por estados o secciones que nos interesen. Finalmente, como se aprecia en las imágenes, estos reportes pueden ser exportados a la web para estar disponibles a los empleados del banco.

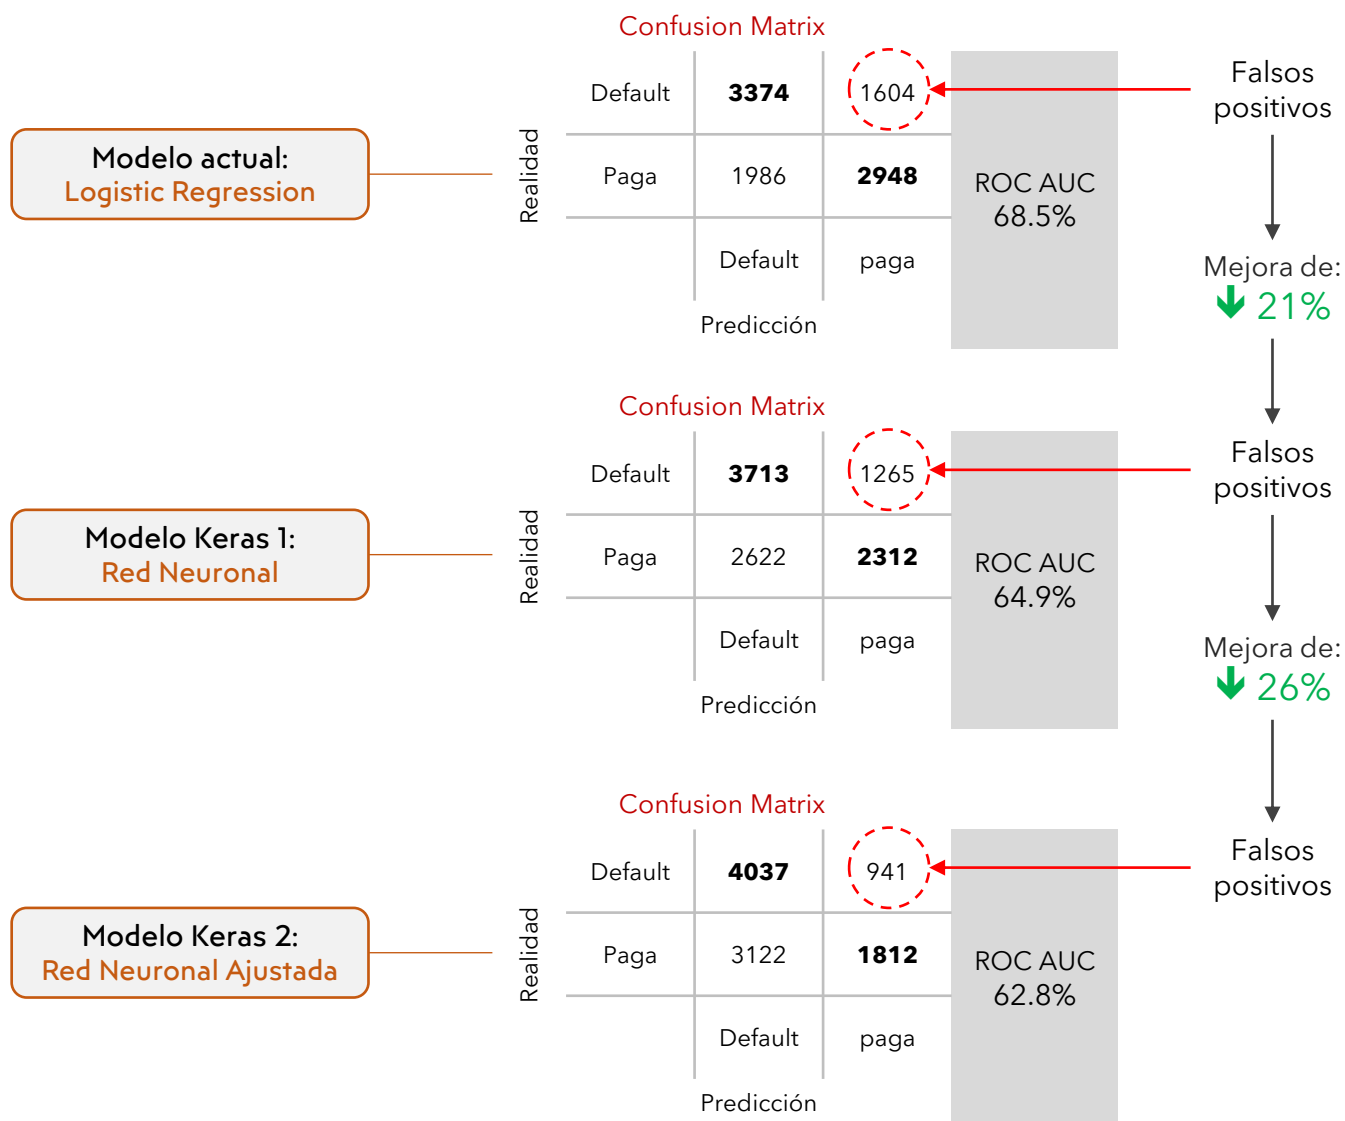


Extras: Deep Learning



Una aproximación simple con redes neuronales

Como un esfuerzo adicional y tomando la clase de Deep Learning de la maestría como base, generé una red neuronal para resolver el mismo problema de default crediticio. El objetivo primordial fue generar una red neuronal en Keras y poder utilizar ese modelo con un pipeline de Sci-Kit Learn. Una vez generada la red neuronal reduje los falsos positivos a través de ajustes en los datos de entrenamiento. ¿Por qué reducir falsos positivos? Porque predecir que el cliente pagará y que el final no pague es un error que le cuesta al banco mucho dinero, tiempo y esfuerzo. Es decir, es un costo financiero y operativo que al final no da ingresos. Los detalles del código en mi GitHub (Ref. #15)



Para minimizar el número de falsos negativos (FN) o falsos positivos (FP), también podemos volver a entrenar un modelo en los mismos datos con valores de salida ligeramente diferentes más específicos de sus resultados anteriores. Este método implica tomar un modelo y entrenarlo en un conjunto de datos hasta que alcance de manera óptima un mínimo global. Si estuviéramos tratando de minimizar los falsos negativos, tomaríamos una cierta cantidad (variable independiente) de los falsos positivos en los datos de entrenamiento y cambiaríamos su valor real

Referencias

1. Lending Club Loan Data. (2021b, junio 17). Kaggle. <https://www.kaggle.com/datasets/adarshnng/lending-club-loan-data-csv>
2. Kawwa, N. (2021, 14 diciembre). Data science for fintech and issuing loans | Towards Data Science. Medium. <https://towardsdatascience.com/how-to-issue-smarter-loans-d0eda750bed9>
3. Ulindala, P. R. (2022, 6 enero). End to End Case Study (Classification): Lending Club data. Medium. <https://towardsdatascience.com/end-to-end-case-study-classification-lending-club-data-489f8a1b100a>
4. Dietz, M., Kincses, A., & Ahmad, F. (n.d.). A new era of divergence. McKinsey & Company. <https://www.mckinsey.com/industries/financial-services/our-insights/banking-matters/a-new-era-of-divergence>
5. The future of AI in banking. (2021, February 24). Deloitte United States. <https://www2.deloitte.com/us/en/pages/consulting/articles/ai-in-banking.html>
6. Comisión Nacional Bancaria y de Valores. (2019). Series Históricas. Portafolio de Información CNBV. <https://portafolioinfo.cnbv.gob.mx/Paginas/Inicio.aspx>
7. Cámara de Diputados del H Congreso de la Unión. (2010, July 5). Ley General de Protección de Datos en Posesión de los Particulares. Diputados Gob MX. <https://www.diputados.gob.mx/LeyesBiblio/pdf/LFPDPPP.pdf>
8. Cámara de Diputados del H Congreso de la Nación. (2007, June 15). Ley de Transparencia y Ordenamiento de los Servicios Financieros. Diputados Gob MX. https://www.diputados.gob.mx/LeyesBiblio/pdf/LTOSF_090318.pdf
9. El último medio siglo de la banca en México. (2023, March 15). Real Estate Market & Lifestyle. <https://realestatemarket.com.mx/articulos/credito/19875-el-ultimo-medio-siglo-de-la-banca-en-mexico>
10. Kelley, S. (2023, March 6). Removing Demographic Data Can Make AI Discrimination Worse. Harvard Business Review. <https://hbr.org/2023/03/removing-demographic-data-can-make-ai-discrimination-worse#:~:text=and%20machine%20learning,Removing%20Demographic%20Data%20Can%20Make%20AI%20Discrimination%20Worse,race%20can%20produce%20fairer%20outcomes>
11. 5 Principles of Data Ethics for Business. (2021, March 16). Business Insights Blog. <https://online.hbs.edu/blog/post/data-ethics>
12. Comisión Nacional Bancaria y de Valores. (2023). Disposiciones De Carácter General Aplicables A Las Instituciones De Crédito. Normatividad CNBV. <https://www.cnbv.gob.mx/Normatividad/Disposiciones%20de%20car%C3%A1cter%20general%20aplicables%20a%20las%20instituciones%20de%20cr%C3%A9dito.pdf>
13. Fawcett, T. (2005). An introduction to ROC analysis. ELSEVIER.
14. Gartner, Inc. (n.d.). Risk Management Software Reviews 2023 | Gartner Peer Insights. Gartner. <https://www.gartner.com/reviews/market/integrated-risk-management>
15. coyoacan - Overview. (n.d.). GitHub. <https://github.com/coyoacan>
13. Jie Zhang, B. R. (2019). Magic Quadrant for Integrated Risk Management Solutions. Gartner, G00369371. <https://www.gartner.com>
14. Mazzanti, S. (2022b, abril 22). SHAP Values Explained Exactly How You Wished Someone Explained to You. Medium. <https://towardsdatascience.com/shap-explained-the-way-i-wish-someone-explained-it-to-me-ab81cc69ef30>
15. Bank of England. (2014, 27 noviembre). What are bank funding costs? Quarterly Bulletin. YouTube. <https://www.youtube.com/watch?v=kFtpWnpqqFA>
16. Communications. (2019, November 21). 'Machine learning', ¿para qué se usa en la banca? BBVA NOTICIAS. <https://www.bbva.com/es/innovacion/machine-learning-para-que-se-usa-en-la-banca/>
17. Cronología de la pandemia en México. (2020). El Economista. <https://www.eleconomista.com.mx/politica/Cronologia-de-la-pandemia-en-Mexico-20210301-0045.html>
18. Forbes, I. (2022, 15 febrero). Las 10 tendencias que darán forma a la banca este año. Forbes México. <https://www.forbes.com.mx/red-forbes-las-10-tendencias-que-daran-forma-a-la-banca-este-ano/>
19. Classification. (s. f.). Google Developers. <https://developers.google.com/machine-learning/crash-course/classification/video-lecture>
20. Annual Reports. (s. f.). <https://www.Banco.com/ca/en/about/investors-shareholders/annual-reports.html>
21. Lademann, J. (2019). Customer experience as the new standard - How can banks successfully realign? Deloitte Digital.
22. The future of banks: A \$20 trillion breakup opportunity. (2022, 20 diciembre). McKinsey & Company. <https://www.mckinsey.com/industries/financial-services/our-insights/the-future-of-banks-a-20-trillion-dollar-breakup-opportunity>
23. LINDDUN. <https://www.linddun.org/>
24. Balakrishnan, S. (2021, December 16). Predicting Loan Defaults using Deep Learning with Keras & Tensorflow. Medium. <https://sarathi-tech.medium.com/predicting-loan-defaults-using-deep-learning-with-keras-tensorflow-78a15b196e65>